

Agent Failure Diagnosis 연구 브리핑

석사과정 공유용 · 2026-08-18

※ 논문 초안·실험 코드·수치는 AI(Claude) 지원으로 작성됨. 전 항목 학생 검증 필요 (6 장 참조).

1. 연구 프로그램 명칭·배경·목적

- 분야의 공식 명칭: failure attribution (실패 귀인). AI 에이전트의 실행 로그에서 실패 원인 단계·주체를 찾는 연구
- 우리 프로그램 명칭: Agent Failure Diagnosis (AI 에이전트 오류 진단). 귀인보다 넓은 상위 개념을 채택
- 개념 계층: 진단(diagnosis) > 귀인(attribution) > 위치추정(localization)
- 이렇게 이름 지은 이유
 - MIS 정체성: 귀인 정확도 경쟁은 공대 영역이고 현재 최고 성능도 낮음(단계 정확도 12~25%). 진단·점검·감리 체계 수립은 회계감사·IS 감리를 다뤘은 경영정보 분야의 전통 강점
 - 학생 취업: "에이전트 로그 진단·분석" 역량은 AI 운영·품질·감사 직무 수요와 직결. 논문 실적 + 실무 포트폴리오(진단 리포트) 동시 확보 가능
 - 실용 경로: 국내지 논문 → 진단 체크리스트 → 소액 진단 용역 → AI 감리 기준화 (AI 기본법 등 규제 수요 연계)
- 프로그램의 목적 3 가지
 - ① 서베이를 통한 연구 동향 습득: failure attribution·진단 분야 문헌을 체계적으로 읽고 정리
 - ② 체크리스트를 통한 진단 선점: 진단 체크리스트와 진단가능성 계측을 이 분야에서 먼저 제시
 - ③ 세부 연구 다수 수행: 위 과정에서 습득한 지식과 데이터·도구를 토대로 후속 세부 연구를 여러 편 파생 (귀인 기법, 인간 검증, 민감도 분석, 로깅 설계 등)
- 용어 사용: 대외·수업에서는 "AI 에이전트 오류 진단", 논문·키워드에서는 국제 표준 용어(failure diagnosis, failure attribution) 사용

2. 선행연구 3 편 요약

선행연구와 본 연구의 관계

논문	기여	우리가 취한 내용
Who&When (Zhang et al., ICML 2025 Spotlight)	실패 귀인 과정을 최초로 공식화(누가·어느 단계). 인간 주석 실패 레직 184 건 공개. LLM 귀인 전략 3 종(전체 일괄/단계별/이진 탐색) 제시, 정확도가 낮음을 보고(단계 12~25%)	벤치마크 데이터 184 건. L3-01(최초 오류 단계) 판정에 전체 일괄(all-at-once) 전략 사용. 정답 정합 비교 기준치(Table 6b)
AgentDebug / AgentErrorTaxonomy (Zhu et al., 2025)	인지 모듈 5 종 × 오류 17 유형의 분류 체계. 모듈 태그 로그 + 최정밀 정답 주석(단계+모듈+유형) 200 건 공개. 모듈별 LLM 판정 구현 공개	분류 체계 → 체크리스트 L2 항목의 근간. 벤치마크 200 건. 모듈군 분할 판정 프롬프트 구조를 개작하여 사용(출처 명시)
TRAIL (Deshpande et al., 2025)	산업 관측 표준(OTel 스펙) 로그에 3 대분류 오류 체계로 스펙 단위 다중 주석 148 건 공개. 장문 트레이스에서 LLM 판정의 한계 보고	분류 체계 → L1·L0 항목 보강. 벤치마크 148 건. 산업 로그 형식 대표로서 용역 상품 연결 고리

- 공통점: 세 편 모두 "실패 레직 + 정답 주석" 데이터를 공개 → 우리 실험의 재료. 각자 분류 체계가 달라 서로 호환되지 않음 → 우리 통합(기여 1)의 동기

3. 연구의 핵심

- 한 줄 요약: 실행 로그 1 건에 26 개 점검 질문을 적용해 오류 소견을 산출하는 체크리스트를 만들고(도출), 공개 벤치마크 3 종 532 건 전수에 실제 적용(실증)

체크리스트: 4 계층 26 항목

층	항목	주제
---	----	----

L0	7	기록 점검: 로그에 무엇이 적혀 있는가 (과제 명세, 단계 구분, 모듈 태그, 관찰, 성패 근거, 원시 응답, 메타데이터)
L1	4	시스템·실행 문제: 스텝 한도, 무효 행동, 환경·도구 오류, 무효 반복
L2	10	단계별 사고 실수: 기억 3, 반성 2, 계획 3, 행동 2
L3	5	궤적 전체: 최초 오류 단계, 위치(3분위), 전파 길이, 자기 교정, 유형 반복

- 도출 방법: 위 선행연구의 분류 체계들(+MAST, AgentFail)을 사전 선언 규칙으로 교차 대응, 46개 원 개념 → 26 항목 통합. 항목마다 판정 질문 + 필요 로그 필드 + 판정 방식 명시
- 핵심 개념 — 진단가능성(diagnosability): 필요 필드가 없으면 판정불가 → "26개 중 몇 개 판정 가능한가"가 로그 품질 점수. 이 측정은 본 연구가 최초
- 기여 3가지: ① 분류 체계 통합(대응표) ② 진단가능성 계측 방법 ③ 공개 벤치마크 전수 실측

4. 벤치마크 선정 배경과 데이터 취득 경로

- 선정 조건: 실패 궤적 + 인간 정답 주석(오류 위치·유형)이 함께 공개된 데이터
- 의도적으로 로그 형식이 서로 다른 3종 선택 — "진단가능성은 로그 형식이 결정한다"는 주장의 검증에 형식 대비가 필수
- 부수 효과: 동일 GAIA 과제가 AEB·TRAIL 양쪽에 다른 형식으로 존재 → 과제 고정, 형식 효과만 비교 가능

데이터 취득 경로 (재배포 금지 조건 유의, 각자 원 출처에서 취득)


벤치마크	규모	다운로드 경로	취득 방법
Who&When	184 건	github.com/mingyin1/Agents_Failure_Attribution → Who&When/폴더	git clone (즉시 가능)
AgentErrorBench	200 건	github.com/ulab-uiuc/AgentDebug 안내의 저자 Google Drive 폴더 (저장소에는 코드만 있음)	Drive에서 폴더 다운로드(자동 zip)
TRAIL	148 건	huggingface.co/datasets/PatronusAI/TRAIL → data/ 폴더의 parquet 2개	HF 로그인 → 이용 조건 동의 → 파일 2개 다운로드

5. 지금까지 한 일 (2026-08-18 기준)

- 데이터: 3종 532건 확보(Who&When은 AI가 클론, AEB·TRAIL은 교수가 다운로드·업로드) → 공통 형식 traces.jsonl로 정규화. 정답-궤적 매칭·단계 번호 규약 전수 검증, 불량 6건 제외·문서화
- 프로그램 5종 제작·검증: 정규화 / 커버리지 계산 / 정답 분포 계산 / 일치도(κ ·AC1) 계산 / LLM 판정 파이프라인(API 키만 넣으면 실행)
- 실험 E1 (실측 완료, 비용 0): 진단가능성 커버리지 38.5~76.9%. 발견 3개 — ① AEB는 사고 총 만점·시스템 총 바닥, TRAIL은 반대(인자·시스템 기록을 동시에 갖춘 벤치마크 없음) ② 같은 GAIA 과제가 형식 따라 50.0% 대 61.5% ③ 스텝 한도 항목은 7개 서브셋 전부 판정불가

층별 커버리지 (실측)

벤치마크 (n)	L0 (/7)	L1 (/4)	L2 (/10)	L3 (/5)	전체
AEB ALFWorld·WebShop (150)	4 (57.1)	1 (25.0)	10 (100)	5 (100)	76.9%
AEB GAIA (50)	4 (57.1)	1 (25.0)	4 (40.0)	4 (80.0)	50.0%
TRAIL GAIA·SWE (148)	5 (71.4)	3 (75.0)	4 (40.0)	4 (80.0)	61.5%
Who&When AG+HC (184)	3 (42.9)	0 (0.0)	3~7	4 (80.0)	38.5~53.8%



- 정답 주석 분포 (실측 완료): 최초 오류는 궤적 초반 1/3 에 편중(48~67%), 전파 길이는 긴 궤적에서 급증(최대 124 단계)
- 판정 파일럿 9 건 (실측 완료): 정답 격리 후 판정·대조 — 오류 단계 오차 3 이내 8/9, 에이전트 지목 4/4, 모듈 지목 1/5(정답은 표면 발현, 심사자는 근본 원인을 지목하는 관점 차 → 단계 중심 보고 방침 확정)
- 문서: 논문 초안 v0.2 12 쪽(실측 반영, 그림 4 종, 가상 수치는 표에 명기) + 지표 산출 명세서 4 쪽 + 프로그램 zip
- 미실행: E2(판정 안정성)·E3(오류 발생 비율) — API 필요, 견적 표준 \$128 / 배치 \$64

6. 향후 할 일 (검증 포함)

- **(1) AI 작성 초안 검증 [최우선, 학생]**
 - 논문 전체 정독(논리·용어·문체) / Table 2 대응의 타당성을 원문과 대조
 - 서지 검증: [9], [10], [16]~[22] 실존 여부·정보 정확성 원문 확인 (AI 생성 서지는 오류 가능)
 - 판정 프롬프트 원문과 체크리스트 정의의 일치 검토
- **(2) 실험 재현·검증 [학생]**
 - traces.jsonl 재생성 → 커버리지 재계산 → 논문 Table 7·부록 A1 수치 재현 확인 / 제외 6 건 사유 원 데이터 확인
 - 파일럿 확대: 학생 2 인이 각 5~10 건 독립 판정 → 상호·정답 대조 (인간 일치도 확보 시 후속 연구 v2 씨앗)
- **(3) 본 실험 실행 [API 키 확보 후]: 20 건 테스트 → 전수 실행(배치 약 \$64) → 가상 표 4 개(Table 6·6b·8b·9) 실측 교체, Table 6b 벤치마크별 분해**
- **(4) 논문 마무리·투고: 신규성 재검색, 판정 절차 출처 명시 + 핵심 프롬프트 그림 삽입, 저자 확정, JKSCI 양식 점검**
- **(5) 파생 세부 연구 후보: 윈도우 증강의 단일 에이전트 이식, 인간 검증 기반 v2, 민감도 분석, 로깅 설계 지침, 한국어 서베이, 특허 1 건**