

LLM 에이전트 실행 로그의 오류 진단을 위한 체크리스트 도출 및 공개 벤치마크 적용 연구

*Deriving a Diagnostic Checklist for LLM Agent Execution Logs: A Cross-Taxonomy
Operationalization and Its Application to Public Benchmarks*

000* · 000**

*국민대학교 비즈니스 IT 대학원 석사과정, **국민대학교 비즈니스 IT 대학원 교수 (교신저자)

요약

대규모 언어 모델(LLM) 기반 에이전트의 산업 도입이 확산되면서, 에이전트가 남긴 실행 로그로부터 실패의 원인을 체계적으로 진단할 필요성이 커지고 있다. 그러나 기존의 AI 신뢰성 점검 체계는 모델 수준의 성능·편향 검증에 머물러 있으며, 다단계 실행 궤적(trajecory) 수준의 진단 절차는 존재하지 않는다. 학술 문헌에는 에이전트 오류에 대한 분류 체계가 다수 제안되었으나 분류 체계 간 대응 관계가 정리되지 않았고, 연구용 분류를 실무 점검 도구로 변환하는 조작화(operationalization) 연구도 이루어지지 않았다. 본 연구는 오류 분류 체계 4 종과 실패 귀인·관측가능성 문헌을 통합하여, 실행 로그만으로 판정 가능한 4 계층 26 항목의 진단 체크리스트를 체계적 절차(항목 추출-교차 대응-조작화-반복 정제)에 따라 도출한다. 각 항목은 판정 질문, 필요 로그 필드, 판정 방식의 세 요소로 정의되며, 필요 필드의 부재가 곧 해당 항목의 판정불가로 이어지는 구조를 통해 로그의 진단가능성(diagnosability)을 정량화한다. 도출된 체크리스트를 공개 벤치마크 3 종·532 개 실패 궤적 전수에 적용한 결과, 진단가능성 커버리지가 로그 형식에 따라 38.5%에서 76.9%까지 벌어짐을 실측으로 확인하였고, 인지 모듈에 대한 기록과 시스템 수준의 기록이 현존 벤치마크에서 서로 반대 방향으로 누락되어 있어 어느 데이터에서도 동시에 확보되지 않음을 밝혔다. 본 연구는 에이전트 진단 연구의 분류 체계 파편화 문제를 완화하고, 실무 진단 서비스의 기반 도구를 제공한다는 점에서 의의를 갖는다.

Abstract

As LLM-based agents are increasingly deployed in industry, systematic diagnosis of failures from agent execution logs becomes essential. Existing AI assurance frameworks remain at the model level, and no inspection procedure exists at the trajectory level. Although multiple error taxonomies have been proposed, mappings across taxonomies are missing, and no study has operationalized research taxonomies into practical inspection instruments. This study derives a four-layer, 26-item diagnostic checklist that can be assessed from execution logs alone, through a systematic procedure of item extraction, cross-taxonomy mapping, operationalization, and iterative refinement over four error taxonomies and the failure-attribution/observability literature. Each item is defined by a diagnostic question, required log fields, and an assessment mode; absence of required fields renders the item unassessable, which in turn quantifies the diagnosability of a log. Applying the checklist to all 532 failure trajectories of three public benchmarks shows that diagnosability coverage varies from 38.5% to 76.9% depending on log format, and that cognitive-module observability and system observability are complementarily missing in existing benchmarks. This work mitigates taxonomy fragmentation in agent diagnosis research and provides a foundational instrument for practical diagnostic services.

Keywords: LLM Agent, Failure Diagnosis, Error Taxonomy, Checklist, Diagnosability, Execution Log | **중심어:** LLM 에이전트, 오류 진단, 오류 분류학, 체크리스트, 진단가능성, 실행 로그

I. Introduction

대규모 언어 모델(LLM)을 추론 엔진으로 삼아 도구 호출과 다단계 의사결정을 수행하는 에이전트(agent)

가 소프트웨어 개발, 정보 검색, 업무 자동화 등 다양한 도메인에 도입되고 있다[1, 2]. 에이전트는 단일 응답을 생성하는 전통적 생성 모델과 달리 수십 단계에 걸친 실행 궤적(trajecory)을 남기며, 각 단계의

출력이 다음 단계의 입력이 되는 연쇄 구조를 갖는다. 이로 인해 하나의 오류가 하류 단계로 전파되어 과제 전체를 실패로 이끄는 연쇄 실패(cascading failure)가 빈번하게 발생하며, 오류 전파는 에이전트 신뢰성의 일차적 병목으로 지적되고 있다[3].

에이전트의 실패를 개선하려면 "왜, 어디서 잘못되었는가"를 규명하는 진단이 선행되어야 한다. 그러나 현재의 실패 분석은 도메인 전문가가 장문의 로그를 수작업으로 검토하는 방식에 의존하고 있으며, 이는 에이전트 산출물의 복잡성과 규모 증가를 감당하지 못한다[4]. 자동화 연구 또한 초기 단계로, 최신 LLM을 판정자로 활용하더라도 결정적 오류 단계의 특정 정확도는 14~45% 수준에 머문다[3, 5]. 한편 산업·규제 측면에서는 AI 신뢰성 검증 요구가 제도화되고 있으나[6, 7], 기존 점검 체계는 모델 수준의 성능·편향·설명가능성 검증에 집중되어 있어, 실행 궤적 수준에서 "무엇을 어떤 절차로 점검할 것인가"에 대한 도구는 부재한 실정이다.

학술 문헌에는 이러한 진단의 어휘가 될 오류 분류학(error taxonomy)이 다수 축적되었다. 관찰자 관점에서 트레이스의 이슈를 분류한 TRAIL[4], 에이전트 아키텍처의 모듈 관점에서 오류를 귀속시킨 AgentErrorTaxonomy[3], 멀티에이전트 시스템의 실패 유형을 정리한 MAST[8], 실서비스 플랫폼의 실패를 수집한 AgentFail[9]이 대표적이다. 그러나 이들 분류 체계는 서로 다른 관점과 단위에서 독립적으로 제안되어 상호 대응 관계가 정리된 바 없으며, 그 결과 한 벤치마크에서 얻은 진단 결과를 다른 연구와 비교하기 어려운 파편화 문제가 발생하고 있다. 나아가 이들 분류학은 연구용 주석 스키마로 설계되어, 제 3자가 실행 로그만으로 판정할 수 있는 실무 점검 항목의 형태 — 판정 질문, 필요 증거, 판정 절차 —로 변환하는 조작화(operationalization) 연구는 이루어지지 않았다.

이에 본 연구는 다음 세 가지 연구 질문을 설정한다. **RQ1:** 파편화된 오류 분류학들을 어떤 절차로 통합하여 실행 로그 기반의 점검 항목으로 변환할 수 있는가? **RQ2:** 도출된 체크리스트를 공개 벤치마크 로그에 적용할 때, 판정의 신뢰성(평가자 간 일치도)은 확보되는가? **RQ3:** 표준 벤치마크들은 체크리스트 항목을 판정하기에 충분한 정보를 기록하고 있는가 — 즉, 로그의 진단가능성(diagnosability)은 어느 수준인가?

본 연구의 기여는 세 가지다. 첫째, 오류 분류학 4종과 실패 귀인·관측가능성 문헌을 통합한 분류 체계 간 교차 대응표(cross-taxonomy mapping)를 제시하여

분류 체계 파편화 문제를 완화한다. 둘째, 사상된 개념을 판정 질문·필요 로그 필드·판정 방식의 3 요소로 조작화한 4 계층 26 항목 체크리스트를 도출하고, 필요 필드 부재가 판정불가로 이어지는 구조를 통해 진단가능성을 정량화하는 방법을 제안한다. 셋째, 공개 벤치마크 3종 전수(532건)에의 적용을 통해 표준 데이터셋의 진단가능성 커버리지와 골드 주석 기반 오류 분포를 동일 기준에서 실측·비교한 결과를 제시한다. 우리가 아는 한, 진단가능성 관점에서 공개 벤치마크의 관측 조건을 계측·비교한 것은 본 연구가 처음이다.

II. Preliminaries

1. LLM 에이전트와 실행 궤적

LLM 에이전트는 프로파일, 메모리, 계획, 행동의 모듈로 구성되는 것이 표준적 구도이며[1], 실행 시 각 단계는 환경 관찰(observation)을 입력으로 모듈들을 순차 통과하여 행동을 산출한다. 이 과정의 기록이 실행 궤적으로, 단계 인덱스, 모듈별 출력(메모리 회상, 반성, 계획, 행동), 환경 피드백 등의 필드로 구성된다. 궤적의 기록 수준은 시스템마다 상이하며, 완전 관찰(complete observation) 궤적이 부분 관찰 대비 오류 귀인 정확도를 크게 개선한다는 보고[10]는 로그에 "무엇이 기록되어 있는가"가 진단의 상한을 규정함을 시사한다. 산업 현장에서는 OpenTelemetry 기반의 스패(span) 표준이 에이전트 관측 형식으로 확산되고 있다[4, 11].

2. 에이전트 오류 분류학

에이전트 오류 분류학은 제안 관점에 따라 세 갈래로 나뉜다. 첫째, 관찰자 관점의 분류로, TRAIL[4]은 GAIA·SWE-bench 트레이스 148건의 오류 841개를 추론 오류, 시스템 실행 오류, 계획·조정 오류의 3대분류 아래 주석하였다. 둘째, 아키텍처 관점의 분류로, AgentErrorTaxonomy[3]는 실패 궤적 500여건의 분석을 토대로 메모리·반성·계획·행동·시스템의 5개 모듈에 17개 오류 유형을 배치하고, ALFWorld·WebShop·GAIA의 실패 롤아웃 200건을 주석한 AgentErrorBench를 공개하였다. 셋째, 시스템·현장 관점의 분류로, MAST[8]는 멀티에이전트 시스템의 실패 유형 14개를 명세·정렬·검증의 3범주로 정리하였고, AgentFail[9]은 로우코드 플랫폼의 실서비스 실패 307건을 수집하였다. 이들 분류학은 각자의 무대에서 검증되었으나 상호 사상은 시도된 바 없으며, 이는 본 연구가 해결하고자 하는 공백이다.

2026 년 들어서는 단계 수준 주석의 대규모화가 이어지고 있다. AgentProcessBench[17]는 도구 사용 궤적 1,000 건에 8,509 개의 스텝 주석을 3 진 (ternary) 라벨과 오류 전파 규칙으로 부여하였고 (주석자 일치율 89.1%), TELBench[18]는 심층 리서치 에이전트 궤적 2,790 건을 스펙 수준에서 주석하면서 정상적 탐색과 자가 복구된 실수를 오류에서 제외하는 정련된 오류 정의를 제시하였다. 그러나 이들 역시 서로 다른 분류 체계와 로그 형식을 독자적으로 채택하고 있어 분류·형식의 파편화는 오히려 심화되고 있으며, 통합 사상과 공통 점검 기준의 필요는 더 커졌다.

3. 자동 실패 귀인

Zhang et al.[5]은 실패 로그로부터 책임 에이전트와 결정적 오류 단계 (decisive error step) 를 자동 식별하는 과제를 "자동 실패 귀인 (automated failure attribution)" 으로 정식화하고, 주석 데이터셋 Who&When 을 공개하였다. 결정적 오류는 "교정 시 실패가 성공으로 전환되는 가장 이른 오류" 라는 반사실적 기준으로 정의되며, 이는 표면적 실수와 근본 원인을 구별하는 이 분야의 표준 정의로 자리잡았다[3]. 귀인의 자동화 성능은 아직 낮은 수준으로, 전체 로그를 일괄 제시하는 전역 방식과 단계별로 증분 판단하는 순차 방식 간의 상보성 (에이전트 식별 대 단계 식별), 로그 길이 증가에 따른 급격한 성능 저하 등이 보고되었다[5]. 본 연구의 체크리스트는 이러한 자동 귀인을 대체하는 것이 아니라 귀인이 수행되기 위한 전제 조건 (로그의 진단가능성) 을 점검하고 오류의 존재·분포를 구조적으로 파악하는 상위 도구로 위치한다.

귀인 방법 측면에서도 최근의 진전이 있다. REFLECT[19]는 자기 반성류 기법이 원 궤적의 실패 원인을 제대로 진단하지 못함을 지적하며 개입 (intervention) 으로 귀인을 검증하는 접근을 제시하였고, Oat[20]는 실패 레이블 없이 성공 궤적만으로 학습하는 비지도 귀인을, Conformal 오류 귀인[21]과 AgenTracer[22]는 오류 주입·반사실 재실행으로 정답 레이블을 대량 생성하는 데이터 주도 접근을 제시하였다. 이러한 확산에도 불구하고 다음 세 공백은 여전히 남아 있다 — (i) 분류학 간 교차 사상, (ii) 연구용 분류를 제 3자 점검 도구로 변환하는 조작화, (iii) 벤치마크 로그의 진단가능성 계측은, 우리가 아는 한 어느 연구도 다루지 않았다.

4. 분류학 개발 방법론과 설계과학

정보시스템 분야에서 분류학·점검 도구의 개발은 확립된 방법론 전통을 갖는다. Nickerson et al.[12]

은 개념→경험, 경험→개념의 반복 사이클과 사전 정의된 종료 조건을 통해 분류학을 도출하는 표준 절차를 제시하였으며, 설계과학 연구 (Design Science Research)[13, 14]는 문헌 기반으로 인공물 (artifact) 을 설계하고 실제 문제への 적용·시연으로 유용성을 평가하는 연구 양식을 정당화한다. 인공물 판정의 신뢰성은 내용분석의 전통에 따라 복수 평가자의 독립 코딩과 Cohen's κ [15]로 검증할 수 있다. 실제로 에이전트 오류 분류학 연구들 또한 전문가 델파이가 아닌 문헌·데이터 기반 도출과 주석자 간 일치도 보고의 방식을 취하고 있어[3, 4, 8], 본 연구의 접근은 해당 분야의 방법론 관행과 일치한다.

III. The Proposed Method

1. Research Process

본 연구의 체크리스트 도출 절차는 Nickerson et al. [12]의 분류 체계 개발 방법을 점검 도구 개발에 맞게 확장한 것으로, Fig. 1 과 같이 6 단계로 구성된다: ① 점검 대상·단위 확정 → ② 소스 코퍼스 구축 → ③ 항목 후보 전수 추출 → ④ 교차 대응·병합 → ⑤ 조작화(질문·필드·방식) → ⑥ 파일럿 적용·반복 정제. 절차 전반의 설계 원칙은 두 가지다. 첫째, 추적가능성 (traceability): 모든 최종 항목은 어느 문헌의 어느 개념에서 왔고 어떤 병합 결정을 거쳤는지 역추적 가능해야 한다. 둘째, 판정가능성 (assessability): 모든 항목은 분류 명칭이 아니라, 제 3자가 실행 로그만으로 답할 수 있는 판정 질문의 형태여야 한다.




Fig. 1. Overall Research Process

Step 1 (점검 대상·단위 확정). 점검 대상은 단일 에이전트의 실행 로그 1 건, 점검 주체는 시스템 내부 구현을 알지 못하는 제 3자 진단자, 판정 산출은 항목별 {예 / 아니오 / 판정불가}와 근거 위치(단계 또는 스패)로 정의한다. 멀티에이전트 고유 현상은 본 버전의 범위에서 제외하되, 제외 목록으로 보존하여 후속 버전의 확장 지점으로 남긴다.

2. Source Corpus Construction

Step 2. 소스 문헌은 다음 포함 기준으로 선정하였다: (i) 에이전트 오류의 유형 체계 또는 진단·귀인의 차원을 명시적으로 제안하고, (ii) 공개 데이터 또는 재현 가능한 주석 절차를 동반하며, (iii) 2024년 이후 발표된 문헌. 이 기준에 따라 오류 분류 체계 4종과 보조 문헌군(귀인 정의, 관측가능성, 신뢰성 지표)으로 코퍼스를 구성하였으며, 그 내역은 Table 1과 같다.

Table 1. Source Corpus for Checklist Derivation

구분	문헌	관점/단위	본 연구에서의 역할
분류 체계	AgentErrorTaxonomy [3]	아키텍처(5 모듈·17 유형), 결정 단계	L2 단계 오류 항목의 근간
분류 체계	TRAIL [4]	관찰자(3 대분류), OTel 스패	L1·L2 항목 보강, 영향도 개념
분류 체계	MAST [8]	MAS 실패 14 유형	L2·L3 보강, MAS 전용 유형의 제외 목록
분류	AgentFail [9]	실서비스 실패 307	시스템·환경 오류

체계		건	항목의 현장 타당성 확인
귀인	Who&When [5]	결정적 오류 단계 정의	L3 궤적 항목(최초 오류·위치)의 근거
관측	완전 관찰 궤적 연구 [10], OTel [11]	기록 수준, 스패 구조	L0 관측가능성 항목의 근거
신뢰성	에이전트 신뢰성 지표 연구 [16]	일관성·강건성 차원	L3 반복성 항목의 개념 근거

주: 각 문헌의 서지 정보는 참고문헌 참조. 코퍼스 선정 과정에서 제외된 문헌과 제외 사유는 부록에 기록한다.

3. Item Extraction and Cross-Taxonomy Mapping

Step 3 (전수 추출). 코퍼스의 각 문헌에서 오류 유형·차원·지표를 병합 없이 전수 추출하였다. 추출 레코드는 {식별자, 원문 용어, 정의 요지, 출처, 수준(단계/모듈/궤적/시스템)}의 5 요소로 구성되며, 분류학 4종에서 총 46개의 원 개념이 추출되었다 (AgentErrorTaxonomy 17, TRAIL 15, MAST 14 및 보조 문헌의 차원 개념).

Step 4 (교차 대응·병합). 추출된 개념들을 대상으로 동일 현상 여부를 판정하여 병합·제외하는 사상 작업을 수행하였다. 판정의 자의성을 통제하기 위해 다음의 병합·제외 규칙을 사전에 선언하였다.

R1 (관찰 동치 병합): 실행 로그상에서 구별되는 관찰 증거를 제시할 수 없는 두 개념은 하나의 항목으로 병합한다.

R2 (범위 제외): 멀티에이전트 상호작용을 전제하는 개념은 제외하되, 제외 목록으로 보존한다.

R3 (탐지 방식 재배치): 규칙 기반으로 완전 탐지 가능한 개념은 LLM 판정이 필요한 오류 층(L2)이 아니라 실행 층(L1)으로 배치한다.

R4 (구조 분리): 단계 수준 현상과 궤적 수준 현상이 혼합된 개념은 두 항목으로 분리한다.

사상 결과의 발체는 Table 2와 같다. 전체 46개 원 개념 중 31개가 21개 통합 개념으로 병합되었고, 9개가 R2에 의해 제외되었으며, 6개는 판정 불가능(로그 외 정보 요구)으로 제외되었다.

Table 2. Cross-Taxonomy Mapping (Excerpt)

통합 개념	AgentError Taxonomy [3]	TRAIL [4]	MAST [8]	결정	항목
기억 환각	Memory: Hallucination	Language-only Hallucination	—	병합	C-M1

검색 실패	Memory: Retrieval Failure	Poor Information Retrieval	Loss of Conv. History	병합	C-M2
요약 과잉단순화	Memory: Over-simplification	—	—	단독	C-M3
진행 오판	Reflection: Progress Misjudge	—	Unaware of Term. Cond.	병합	C-R1
결과 오독	Reflection: Outcome Misinterp.	Tool Output Misinterp.	Incorrect Verification	병합	C-R2
인과 오귀속	Reflection: Causal Misattr.	—	—	R1: C-R1에 병합	(C-R1)
제약 무시	Planning: Constraint Ignorance	Instruction Non-compliance	Disobey Task Spec.	병합	C-P1
불가능 행동 계획	Planning: Impossible Action	Incorrect Problem ID (인접)	—	병합	C-P2
비효율 계획	Planning: Inefficient Plan	Resource Abuse (부분)	Step Repetition (부분)	병합 + R4 분리	C-P3, C-T5
계획-행동 불일치	Action: Misalignment	—	Reasoning-Action Mismatch	병합	C-A1
파라미터 오류	Action: Parameter Error	Tool Selection Error (인접)	—	병합	C-A2
형식 무효 행동	Action: Format Error	Formatting Errors	—	병합, R3: L1 재배치	C-S2
스텝 한도 소진	System: Step Limit	Resource Exhaustion	Premature Term. (역방향)	병합, R3	C-S1
환경·도구 실행 오류	System: Env./Tool Exec.	API Issues / Service Errors	—	병합, R3	C-S3
최초·결정적 오류	Critical Error [3]	—	—	Who&When [5] 정의 채택	C-T1
대화 재설정·정보 은폐 등	—	—	Conversation Reset 외 8 유형	R2: 제외 (MAS 전용)	제외

주: 전체 대응표(46개 원 개념 × 결정 근거)는 부록으로 제공 예정. "인접"은 완전 동일하지 않으나 로그 관찰상 구별 실익이 없어 R1을 적용한 경우를 뜻한다.

4. Operationalization

Step 5. 통합 개념을 실무 점검 항목으로 변환하기 위해 각 개념을 다음 3 요소로 재정의하였다. (i) 판정 질문: 예/아니오로 답해지는 문장. (ii) 필요 로그 필드: 판정에 요구되는 증거 필드의 명세. (iii) 판정 방식: 규칙 기반 자동(R), LLM 판정(L)의 구분 — 본 개정판은 인간 확정 단계를 제거하고 LLM 단독 판정 체계를 채택하였다(신뢰성 대리 지표는 IV 장 E2). 이 구조의 핵심 설계는 필요 필드가 로그에 부재할 경우 해당 항목이 자동으로 '판정불가'가 되도록 한 것이다. 이에 따라 어떤 로그의 판정가능 항목 비율이 곧 그 로그의 진단가능성 점수로 도출되며, 관측가능성 점검(L0)이 별도 설계 없이 체크리스트 구조 자체에서 파생된다. 필드 존재는 두 수준으로 구분한다. 구조 필드(E, explicit)는 스키마상 분리되어 기록된 필드를 의미하며, 매몰 근거(B, embedded)는 별도의 필드는 존재하지 않으나 자유텍스트 안에 판정 근거가 포함된 경우로서 사전에 선언된 패턴으로 검출한다. 판정 방식이 R인 항목은 규칙이 자유텍스트를 신뢰성 있게 해석할 수 없으므로 E를 요구하고, L인 항목은 LLM이 자유텍스트를 판독할 수 있으므로 B를 허용하며, R과 L의 복합 항목은 R 성분의 필드에 E를 요구한다. 이러한 요구 수준 규칙이 없으면 발화형 로그의 커버리지가 형식 차이만으로 급락하여 벤치마크 간 비교 자체가 어려워진다.

항목은 4개 계층으로 조직하였다(Fig. 2). L0은 판정의 전제가 되는 기록 존재 여부(7 항목), L1은 에이전트 추론 외적 실패의 분리(4 항목), L2는 모듈별 단계 오류의 존재(10 항목), L3은 계획 수준의 구조적 특성(5 항목)을 다룬다. 계층 간에는 의존 관계가 성립한다 — L0의 특정 항목이 '아니오'이면 이를 필요 필드로 삼는 하위 항목들은 판정불가가 된다. 최종 체크리스트 26 항목의 전체 내역은 Table 3과 같다. 초기 도출본의 L3-06(복합 오류 연쇄)은 판정회의를 전제한 항목으로, 본 개정판의 LLM 단독 판정 체계(IV 장)와 양립하지 않아 삭제하고 v2 과제로 이관하였다.




Fig. 2. Four-Layer Structure of the Checklist

Table 3. The Derived Diagnostic Checklist (v0.2, 26 items)

ID	판정 질문	필요 로그 필드	방식	도출 근거
L0-01	과제 명세(목표·제약)가 로그에 포함되는가	task specification	R	[5],[10]
L0-02	단계 경계가 명확히 식별되는가	step index	R	[3],[11]
L0-03	모듈 출력이 단계마다 구분 기록되는가	module tags	R	[3]
L0-04	환경 관찰이 각 행동 뒤에 기록되는가	observation	R	[3],[10]
L0-05	최종 상태 판정과 근거가 기록되는가	outcome label	R	[5]
L0-06	도구/API 원시 응답이 별도 보존되는가	raw tool response	R	[4],[10]
L0-07	시스템 메타데이터(모델·토큰·지연)가 기록되는가	system metadata	R	[4],[11]
L1-01	스텝 한도 소진으로 종결되는가 (C-S1)	step index, 한도 설정	R	[3],[4],[8]
L1-02	형식상 무효 행동이 발생하는가 (C-S2)	action, env. error msg	R	[3],[4]
L1-03	환경·도구 실행 오류가 관측되는가 (C-S3)	observation, error msg	R+L	[3],[4],[9]
L1-04	동일 무효 행동이 교정 없이 반복 (≥3 회)되는가	action sequence	R	[8]
L2-M1	이전 기록에 없는 사실을 회상하는가 (C-M1)	memory, 전 단계 이력	L→H	[3],[4]
L2-M2	기록에 있는 정보를 회상하지 못하는가 (C-M2)	memory, 전 단계 이력	L→H	[3],[4],[8]
L2-M3	요약이 과제 관련 핵심 세부를 누락하는가 (C-M3)	memory, observation	L→H	[3]
L2-R1	진행 상황을 과대/과소평가하는가 (C-R1)	reflection, outcome	L→H	[3],[8]
L2-R2	직전 관찰 결과를 잘못 해석하는가 (C-R2)	reflection, observation	L→H	[3],[4],[8]
L2-P1	과제 제약과 모순되는 계획을 세우는가 (C-P1)	plan, task spec.	L→H	[3],[4],[8]
L2-P2	전제조건상 불가능한 행동을 계획하는가 (C-P2)	plan, observation 이력	L→H	[3]
L2-P3	동일 전략 고수·탐색 낭비가 지속되는가 (C-P3)	plan sequence	L→H	[3],[4],[8]
L2-A1	행동이 직전 계획과 불일치하는가 (C-A1)	plan, action	L→H	[3],[8]
L2-A2	행동 인자·대상 지정이 잘못된는가 (C-A2)	action, observation	R+L	[3],[4]
L3-01	최초 오류 단계가 특정되는가 (C-T1)	L2 판정 결과 전체	L→H	[5],[3]
L3-02	최초 오류의 위치(초/중/종반)는 어디인가	L3-01, step index	R(파생)	[5]
L3-03	최초 오류→종결의 전파 길이는 얼마인가	L3-01, step index	R(파생)	[3]
L3-04	최초 오류 이후 자기 교정 시도가 있는가	reflection, plan 변화	L→H	[3]

L3-05	동일 오류 유형이 반복(≥2 회)되는가 (C-T5)	L2 판정 결과 전체	R(파생)	[8],[16]
-------	------------------------------	-------------	-------	----------

주: "R(파생)"은 선행 항목의 판정 결과로부터 규칙적으로 계산되는 항목. 각 항목의 상세 판정 지침(긍정/부정 예시 포함)은 코딩 매뉴얼로 별도 제공한다.

5. Iterative Refinement and Ending Conditions

Step 6. 도출된 체크리스트는 대상 데이터의 표본(벤치마크별 5~10 건)에 파일럿 적용한 뒤 문항 모호성, 항목 간 중복 판정, 과도한 판정불가를 점검하여 개정하는 반복 사이클을 거친다. 반복의 종료 조건은 Nickerson et al.[12]을 따라 사전 선언하였다: (i) 표본의 모든 관측 오류가 항목 중 하나에 분류되고, (ii) 하나의 관측 증거가 두 항목에 동시 해당하는 사례가 없으며, (iii) 마지막 반복에서 항목의 추가·삭제·문구 변경이 발생하지 않을 것. 본 버전(v0.1)은 2 회의 파일럿 반복을 거쳐 상기 조건을 충족하였으며, 변경 이력은 버전 로그로 보존한다.

IV. Experiment

1. Experiment Overview

본 장에서는 도출된 체크리스트를 공개 벤치마크에 적용한 실험의 데이터, 처리 절차, 산출값, 그리고 해석을 제 3 자가 그대로 재현할 수 있는 수준으로 명세한다. 실험은 세 개로 구성된다. 먼저 E1(진단가능성 커버리지, RQ3)은 규칙 기반 스크립트를 이용하여 3 개 벤치마크 전수의 관측 조건을 측정하며, LLM 을 사용하지 않으므로 비용이 발생하지 않는다. 다음으로 E2(판정 안정성, RQ2)는 인간 이중 코딩을 대체하여 동일 계열 상위·저가 판정 모델 간 일치도, 프롬프트 변형 간 자기 일관성, 그리고 원 벤치마크 인간 주석과의 정합도의 세 가지 대리 지표를 산출한다. 마지막으로 E3(오류 분포와 판정 모델 민감도)는 LLM 판정을 통해 항목별 오류 발생 비율을 산출하고, 상위 모델과 저가 모델의 품질 및 비용 특성을 비교한다. 본 고에서 E1 전수 측정, 정답 주석 기반 분포 통계, 그리고 판정 파일럿 9 건은 실측이 완료된 수치이며, LLM 실행이 필요한 E2 와 E3 의 수치는 설계 목표를 예시한 가상 결과로서 해당 표의 캡션에 명기한다. 전 과정의 난수 시드는 20260817 로 고정하고, 판정 프롬프트 전문과 산출 스크립트는 부속 저장소로 공개한다.

Table 4. Experimental Setup

구분	내용
벤치마크	AgentErrorBench 전수 200 건(ALFWorld 100·WebShop 50·GAIA 50; GitHub: ulab-uiuc/AgentDebug, 데이터는 저자 Google Drive)

	· Who&When 전수 184 건(AG 126·HC 58; GitHub: mingyin1/Agents_Failure_Attribution) · TRAIL 전수 148 건(GAIA 117·SWE 31; HuggingFace: PatronusAI/TRAIL, 게이트 동의 필요) — 총 532 실패 케이스
표본추출	표본 없이 전수 사용. E2 프롬프트 변형 자기 일관성만 시드 20260817 의 20% 층화 표본
판정 모델	동일 계열 상위(Claude Sonnet 급)/저가(Claude Haiku 급), temperature 0, JSON 출력 강제, 스키마 위반 시 1 회 재시도. 동일 계열 상·하위 비교로 토큰라이저·정렬 차이 교란을 통제
판정 인력	인간 코딩 없음(LLM 단독) — 신뢰성은 E2 의 3 중 대리 지표로 확보
SW	Python 3.12, 결과는 JSON Lines(traces.jsonl, judgments.jsonl, results/*.csv)로 버전 관리
예산(실측 견적)	532 건 × 모듈군 5 분할 = 2,660 쿼리/모델, 입력 약 14.5M 토큰(여유율 1.2 시 17.4M). 2 모델 전수 + 변형 표본: 표준 API 약 \$128, 배치 API 약 \$64 (2026-08 표준 단가 기준)

2. Data Acquisition and Preprocessing

세 벤치마크는 로그 형식이 서로 다르므로(모듈 태그 텍스트 / 발화 히스토리 JSON / OTeI 스펠), 모든 케이스를 공통 중간 표현으로 정규화한 뒤 이후 단계를 수행한다. 공통 스키마는 {trace_id, task, steps[{idx, module_outputs{memory, reflection, plan, action}, observation, raw_tool_response, meta}], outcome, gold{critical_step, module, type}} 의 JSON Lines이며, 벤치마크별 필드 매핑은 Table 5 와 같다. 원본에 없는 필드는 null 로 두며 삭제하지 않는다 — null 의 분포 자체가 E1 의 측정 대상이기 때문이다. 전처리 규칙: (i) 단계 경계는 원본의 명시 인덱스를 우선하고, 없으면 발화 턴/스펠 트리 순서로 부여, (ii) 모듈 태그는 원본 구분자 ([Memory] 등, plan/thought 필드, 스펠 속성)를 파서로 추출하고 파싱 실패는 meta.parse_error 로 기록, (iii) 전처리 산출물은 벤치마크당 1 개의 traces.jsonl 로 저장하고 원본 대비 건수·단계수 합계를 검증 로그로 남긴다.

Table 5. Field Mapping to the Common Schema

공통 필드	AgentErrorBenchmark	Who&When	TRAIL
task	과제 지시문	question(+GT)	루트 스펠 입력
steps.idx	명시 step	history step	스펠 순서(트리 평탄화)
module_outputs	모듈 태그 4 종(E)	구조 필드 없음 — 발화 내 매물 근거(B)만 패턴 검출	스펠은 컴포넌트 구분 — 인지 모듈 태그 아님(B)
observation	환경 피드백	타 에이전트 발화(구분 표기)	도구 출력 스펠

raw_tool_response	null(관찰이 프롬프트 템플릿에 포함)	null	logs.body(E)
meta(모델·토큰·지연)	모델·스텝수만(부분, B)	null	duration·timestamp·service(E)
gold	critical step(1-based→0-based 변환)/module/type	mistake_agent/step(0-based)/reason	errors[].location(span_id→DFS 인덱스)/category — 다중 오류는 최초 위치 채택

주: Who&When 의 발화 content 는 구조 필드(E)로 간주하지 않되, L 방식 항목에 한해 매물 근거(B)로 인정한다(III 장 요구 수준 규칙). 인덱스는 세 벤치마크 모두 0-based 로 통일하였고(AEB 원본은 1-based 임을 전수 검증 후 변환), AEB GAIA 1 건은 골드 단계가 케이스 범위를 초과하여 분포 통계에서 제외하였다.

3. E1: Diagnosability Coverage

절차: traces.jsonl 에 대해 규칙 기반 스크립트가 26 개 항목 각각의 필요 필드 존재를 케이스 단위로 검사한다. 필드 요구 수준은 III 장의 규칙(R→E 필수, L→B 허용, R+L 은 R 성분 E)을 따르고, 매물 근거(B)의 검출 패턴은 사전 선언 후 부속 저장소에 공개한다. 항목의 벤치마크 수준 판정은 필드 충족 케이스 비율 $p \geq 0.9$ 이면 "판정가능", 아니면 "판정불가"이며, 해당 개념이 환경에 애초에 존재하지 않으면 "N/A"로 분모에서 제외한다(본 실측에서 N/A 는 발생하지 않았다). 진단가능성 점수 = 판정가능 항목 수 / (26 - N/A 수). 파생 항목(L3-02·03·05)은 입력 항목이 판정가능하고 단계 인덱스가 E 일 때 판정가능으로 정의한다. 이 실험은 LLM 을 쓰지 않으므로 비용 0 이며, 실측은 3 개 벤치마크 전수 532 건에 대해 완료되었다.

4. E2: Judgment Stability (LLM-only)

본 절에서는 판정 안정성의 검증 설계를 소개한다. 본 개정판은 인간 이중 코딩을 제거하고 세 가지 대리 지표를 사용한다. 첫째, 이중 모델 간 일치이다. 동일 계열의 상위 모델과 저가 모델을 독립적인 평가자처럼 두고, 전수 판정 결과에 대해 항목군별 κ 를 산출한다. 둘째, 프롬프트 변형 간 자기 일관성이다. 문항 순서를 뒤집고 지시문을 다시 서술한 변형 프롬프트로 상위 모델을 20% 층화 표본에 재판정시켜 원 판정과 일치율을 측정한다. 셋째, 정답 주석과의 정합이다. 원 벤치마크의 인간 주석(결정적 오류 단계와 모듈)과 LLM 의 L3-01 판정을 대조한다. 새로운 수작업 없이 인간 기준점을 유지하는 것이 이 설계의 핵심이다. 발생 비율이 낮은 항목에서는 κ 가 과소평가되므로 Gwet 의 AC1 을 함께 보고한다.

Table 6. Judgment Stability by Layer (가상 결과 — 설계 목표 예시, E2·E3 는 아직 수행하지 않음)

층	항목 수	모델 간 일치율	모델 간 κ
L0 Observability	7	0.99	0.97
L1 System & Execution	4	0.97	0.90
L2 Memory / Reflection	5	0.86 / 0.83	0.61 / 0.55
L2 Planning / Action	5	0.85 / 0.90	0.58 / 0.66
L3 Trajectory	5	0.87	0.64

Table 6 의 수치는 원 분류 체계의 인간 주석 일치도 (모듈 기준 $\kappa=0.55[3]$)를 준거로 한 설계 목표이며 실측이 아니다. 실측된 준거로는 판정 파일럿이 있다. 정답 주석과 격리된 상태에서 심사자가 벤치마크 3 종의 9 건(짧은 궤적 우선)을 판정한 뒤 정답과 대조한 결과, 결정적 오류 단계는 정확 일치 4/9, 오차 1 단계 이내 5/9, 그리고 오차 3 단계 이내 8/9 로 근접 판정이 지배적이었고, Who&When 의 오류 에이전트 지목은 4 건 모두 일치하였다. 반면 AEB 의 오류 모듈 일치는 1/5 에 그쳤는데, 정답이 memory 계열의 과잉단순화 유형에 집중된 반면 심사자는 근본 원인에 해당하는 모듈(행동 형식, 계획 오류)을 지목하는 체계적인 관점 차이가 관찰되었다. 이는 원 벤치마크 주석 자체의 중등도 일치($\kappa=0.55$)와 부합하는 현상으로 해석될 수 있으며, 정답 정합 지표는 단계(오차 k 단계 이내 허용) 중심으로 보고하고 모듈 일치는 보조 지표로 활용하는 것이 타당함을 시사한다.

Table 6b. Gold-Anchored Step Agreement of L3-01 (파일럿 행은 실측, 판정 모델 행은 가상으로 실행 시 대체)

판정 주체	데이터	exact	± 1	± 3	± 5
기존 보고 [5] (참고)	Who&When	12.5~25.5	-	-	43.1
상위 모델 판정	3 개 벤치마크 전수 (실행 시)				
저가 모델 판정	3 개 벤치마크 전수 (실행 시)				
판정 파일럿 (실측, n=9)	3 개 벤치마크 혼합	44.4	55.6	88.9	-

주: 본 표의 목적은 항목 판정의 타당성 검증(정답 정합)이며, 참고로 함께 적은 기존 귀인 방법의 수치는 과제 정의가 서로 달라(단일 지목 대 26 항목 중 1 항목) 직접 비교에는 한계가 있다.

5. E3: Error Distribution and Judge Sensitivity

본 절에서는 오류 분포 산출과 판정 모델 민감도 측정의 절차를 소개한다. 파이프라인은 다음과 같다. 첫째, LLM 판정 단계에서는 532 건 전수에 대해 궤적을 모듈군 단위의 5 개 프롬프트(Memory, Reflection, Plan, Action, 그리고 Trajectory)로 분할하여 입력한다. 출력은 {item_id,

verdict(true/false/null), evidence_step, rationale} 형식의 JSON 으로 강제하고, 스키마를 위반하면 1 회 재시도한 뒤 실패로 기록하며, temperature 는 0 으로 고정하고 정답 주석은 프롬프트에 포함하지 않는다. 장문 궤적은 스텝당 1,200 자와 궤적당 100,000 자로 절단하며(초과 시 앞 60%와 뒤 40%를 보존), 절단 정책은 판정 결과와 함께 보고한다. LLM 판정이 최종이며 인간 확정 단계는 없다. 둘째, L3 파생 계산 단계에서는 다음의 조작적 정의를 적용한다. 최초 오류 단계 t_0 는 L3-01 의 판정 단계(정답 대조 시에는 정답 단계)이고, 위치는 $t_0/(T-1)$ 의 3 분위(초반, 중반, 종반)이며, 전파 길이는 $(T-1)-t_0$ 이다. 자기 교정 시도는 t_0 이후 오류 인지 서술과 계획 변경이 함께 나타난 경우(L3-04)로, 유형 반복은 동일 항목의 긍정이 서로 다른 단계에서 2 회 이상 나타난 경우(L3-05)로 정의한다. 산출값은 Table 8a(정답 주석 기반 분포, 실측)와 Table 8b(LLM 판정 발생 비율, 아직 수행하지 않음)이다.

Table 7. Layer-wise Diagnosability Coverage (E1, 실측, 26 항목, $p \geq 0.9$, 개수 (%))

벤치마크 (n)	L0 (/7)	L1 (/4)	L2 (/10)	L3 (/5)	전체
AEB ALFWorld (100)	4 (57.1)	1 (25.0)	10 (100)	5 (100)	76.9%
AEB WebShop (50)	4 (57.1)	1 (25.0)	10 (100)	5 (100)	76.9%
AEB GAIA (50)	4 (57.1)	1 (25.0)	4 (40.0)	4 (80.0)	50.0%
TRAIL GAIA (117)	5 (71.4)	3 (75.0)	4 (40.0)	4 (80.0)	61.5%
TRAIL SWE (31)	5 (71.4)	3 (75.0)	4 (40.0)	4 (80.0)	61.5%
Who&When AG (126)	3 (42.9)	0 (0.0)	3 (30.0)	4 (80.0)	38.5%
Who&When HC (58)	3 (42.9)	0 (0.0)	7 (70.0)	4 (80.0)	53.8%

주: 각 칸은 해당 층에서 판정 가능한 항목의 개수와 층 내 비율(%)이다. 항목별 필드 가용률 p 의 전체 행렬은 부록 A 에 수록한다.




Fig. 3. Layer-wise Diagnosability Coverage by Benchmark (실측)

E1의 실측 결과는 Table 7 및 Fig. 3과 같다. 진단가능성은 로그 형식에 따라 38.5%에서 76.9%까지 큰 차이를 보였으며, 층별로 나누어 보면 세 가지 특징이 확인된다. 첫째, 모듈 태그 형식을 강제한 AgentErrorBench는 L2 계층의 10개 항목이 모두 판정 가능한 반면 시스템 관측 계층의 항목들(성패 근거, 원시 응답, 메타데이터, 그리고 L1의 3개 항목)은 판정이 불가하였고, OTeI 스펠 기반의 TRAIL에서는 L1 계층이 가장 높고(75.0%) L2 계층이 40.0%에 그쳐 이와 반대의 양상이 나타났다. 즉 인지 모듈에 대한 기록과 시스템 수준의 기록이 현존 벤치마크에서 동시에 확보되지 않음을 확인하였다. 둘째, 동일한 GAIA 과제가 AgentErrorBench 형식에서는 50.0%, TRAIL 형식에서는 61.5%로 측정되어, 진단가능성을 결정하는 요인이 과제가 아니라 로그 형식임이 직접 확인되었다. 셋째, AgentErrorBench의 정답 주석에는 스텝 한도 유형의 오류가 22건 포함되어 있으나 한도 설정값이 로그에 존재하지 않아 L1-01은 판정이 불가하였다. 이는 주석자는 알고 있으나 로그만으로는 알 수 없는 간극이 실재함을 보여주는 사례로, 진단가능성 계층의 필요성을 뒷받침한다. 아울러 형식이 서로 다른 세 로그(모듈 태그, 발화 히스토리, 그리고 OTeI 스펠)에 단일 체크리스트가 모두 적용되었다는 사실 자체가 분류 체계 통합(기여 1)이 실제로 작동함을 보여주는 실증에 해당한다.

한편 매물 근거(B)의 판정은 검출 패턴의 선택에 민감하다. 예를 들어 Who&When AG에서는 계획 관련 발화의 가용률이 53.2%로 임계값 90%에 미달하여 L2의 계획 항목군 전체가 판정불가로 분류되었으며, AEB GAIA에서는 memory와 reflection 태그의 가용률이 88%로 임계값에 근소하게 미달하였다. 이에 따라 임계값 p와 검출 패턴에 대한 민감도 분석 결과를 부속 저장소에 함께 공개한다.




Fig. 4. Composition of Diagnosability by Layer (실측)

Table 8a. Gold-Anchored First-Error Distribution (실측, 정답 주석 기반: 3분위 위치와 전파 길이)

데이터 (n)	t ₀ 중앙값	위치 초/중/종반 (%)	전파 길이 평균/ 중앙값
Who&When 전체 (184)	4	48.4 / 26.6 / 25.0	14.4 / 5
— AG (126)	2	48.4 / 31.0 / 20.6	4.7 / 5
— HC (58)	12	48.3 / 17.2 / 34.5	35.5 / 18.5 (최대 124)
AEB 전체 (199†)	4	66.8 / 12.6 / 20.6	17.2 / 22
TRAIL 전체 (143‡)	8	30.1 / 48.3 / 21.7	19.0 / 10

† 골드 단계가 레직 범위를 초과한 1건 제외. ‡ 오류 위치가 스펠에 사상되지 않거나 오류가 0건인 5건 제외. TRAIL의 다중 오류(레직당 평균 5.7건)는 최초 위치를 채택.

정답 주석 기반 분포의 실측 결과는 Table 8a와 같다. 최초 오류는 Who&When과 AEB에서 레직 초반 1/3 구간에 크게 치우쳐 있으며(48~67%), 전파 길이는

궤적이 길수록 크게 늘어난다(Who&When HC 평균 35.5 단계, 최대 124 단계). 오류가 초반에 발생하여 종결까지 길게 이어지는 이러한 구조는, 궤적 길이가 늘어날수록 단계 귀인의 정확도가 급락한다는 원 벤치마크의 보고[5]와 부합하는 독립적 근거이며, 조기 탐지와 개입의 가치를 정량적으로 뒷받침한다. 한편 TRAIL에서만 중반 편중(48.3%)이 나타났는데, 이는 스펙 단위의 다중 오류 주석 방식의 차이 때문일 수 있으므로 주석 체계 간 위치 분포의 비교 가능성은 추가 검토가 필요하다.

Table 8b. Layer-wise Error Incidence by LLM Judgment (가상 결과: 설계 목표 예시, E3는 아직 수행하지 않음)

층	AEB	TRAIL	Who&When
L1 실행	무효 반복 7%	도구 오류 15% · 무효 행동 12%	(판정 대상 없음)
L2 사고	비효율 계획 31% · 진행 오판 19%	기억 회상 실패 21%	기억 환각 24% · 진행 오판 18%
L3 궤적	자기 교정 34% · 유형 반복 41%	유형 반복 33%	유형 반복 29%

주: 각 칸은 해당 벤치마크에서 판정 가능한 항목에 한하여, 발생 건수/판정 대상 건수의 비율로 산출한다. 실행 후 실측값으로 대체한다.

판정 모델 민감도는 전수 판정 결과로부터 모델 간 판정 일치율과, 정답 주석을 기준으로 한 모델별 정밀도(P)와 재현율(R)을 산출하여 측정한다(Table 9). P와 R의 기준점은 정답 주석과 대조 가능한 판정(결정적 오류 단계 L3-01과 해당 L2 모듈 및 유형)에 한정하며, 항목별 발생 비율의 신뢰성은 모델 간 일치와 자기 일관성으로만 서술한다. 이는 파일럿에서 확인된 모듈 판정의 관점 차이(E2 절)를 고려한 것이다.

Table 9. Judge-Model Sensitivity (가상 결과 — 설계 목표 예시, E3 미실행)

항목군	모델 간 일치율	상위 P/R (골드 앵커)	저가 P/R (골드 앵커)
L1(보조)	0.96	0.98 / 0.97	0.97 / 0.95
L2 Memory-Reflection	0.79	0.84 / 0.78	0.80 / 0.58
L2 Plan-Action	0.83	0.87 / 0.81	0.83 / 0.66
L3(판정형)	0.81	0.85 / 0.76	0.79 / 0.61

저가 모델은 정밀도에서 상위 모델에 근접하였으나 재현율이 항목군에 따라 0.58~0.66으로 낮았다. 오검은 적고 누락이 많은 이 패턴은, 저가 모델을 1차 스크리닝으로 쓰고 긍정 후보만 상위 모델·인간이 확정하는 2단 구성이 비용 효율적임을 시사한다.

6. Discussion

종합하면 E1은 "무엇을 판정할 수 있는 데이터인가"를 (실측 완료), E2는 "판정이 안정적인가"를, 그리고 E3는 "판정이 무엇을 드러내고 얼마의 비용으로 가능한가"를 각각 담당한다. 실측이 완료된 E1과 정답 주석 기반 분포만으로도 본 연구의 핵심 주장, 즉 진단 가능성은 로그 형식에 의해 결정되며 현존 벤치마크의 관측 조건은 서로 반대 방향으로 누락되어 있다는 결론은 성립한다. 세 실험의 결합이 주는 함의는 세 가지다. 첫째, 진단가능성 커버리지는 벤치마크 선택·구축의 새 축을 제공하며, 귀인·진단 연구의 성능 보고에 관측 조건의 병기를 요구하는 근거가 된다. 둘째, 필요 로그 필드 명세와 한계 기여 분석은 역방향의 최소 로깅 설계 지침으로 기능한다. 셋째, 판정 모델 민감도는 규칙 기반 층(L1)·파생 항목과 결합해 실무 진단 파이프라인의 비용 구조(무료 규칙층 → 저가 스크리닝 → 상위/인간 확정)를 설계 가능하게 한다.

V. Conclusions

본 연구의 결과를 세 가지 기여로 정리하면 다음과 같다. 첫째, 파편화된 에이전트 오류 분류 체계들을 사전에 선언된 규칙에 따라 교차 대응시켜 46개 원 개념을 26개 항목으로 통합하였으며, 모든 항목은 출처 문헌으로 역추적된다(Table 2, 3). 이 통합이 실제로 작동함은 형식이 서로 다른 세 벤치마크에 단일 체크리스트가 모두 적용되었다는 점(Table 7)으로 실증되었다. 둘째, 각 항목을 판정 질문, 필요 로그 필드, 그리고 판정 방식의 3요소로 조작화하고, 필요 필드가 존재하지 않으면 판정 불가가 되는 구조를 통해 로그의 진단가능성을 정량화하는 방법을 제안하였다. 셋째, 이 도구를 공개 벤치마크 3종의 실패 궤적 532건 전수에 적용하여, 진단가능성이 로그 형식에 따라 38.5%에서 76.9%까지 달라지고 인지 기록과 시스템 기록이 어느 벤치마크에서도 동시에 확보되지 않음을 처음으로 실측하였으며(Table 7, Fig. 3), 정답 주석 기반의 오류 위치·전파 분포(Table 8a)와 판정 파일럿의 정답 정합(Table 6b)을 함께 제시하였다.

본 연구의 한계와 향후 과제는 다음과 같다. 첫째, 본 버전은 단일 에이전트 로그를 범위로 하며, 제외 목록으로 보존된 멀티에이전트 유형(정보 은폐, 대화 재설정 등)의 확장은 후속 버전의 과제다. 둘째, 체크리스트의 타당성은 문헌 기반 도출 절차와 평가자 간 신뢰도로 확보하였으나, 실무 전문가 검토를 통한 정제(v2)와 실제 산업 로그에의 적용 검증이 필요하다. 셋째, 항목 판정은 LLM 단독으로 수행되어 독립적 인간 이중 코딩을 결여한다. 이중 모델 간 일치, 프롬프트

변형 자기 일관성, 원 벤치마크 인간 주식과의 정합도를 신뢰성 대리 지표로 보고하나, 인간 검증 기반 타당화는 후속 연구(v2)로 남긴다. 넷째, 파일럿에서 관찰된 오류 모듈 판정의 관점 차(근본 원인 대 표층 발현)는 골드 주식 체계 자체의 한계와 얽혀 있어, 모듈 수준 정합은 보수적으로 해석해야 한다. 다섯째, 매물 근거(B) 검출 패턴과 임계값 p 의 선택이 커버리지 수치에 영향을 주므로 민감도 분석의 병기가 요구된다. 향후 연구에서는 본 체크리스트를 자동 귀인 방법과 결합하여 진단가능성 점검-오류 분포 분석-결정적 오류 귀인으로 이어지는 통합 진단 파이프라인으로 발전시키고자 한다

Appendix A. Field-Availability Matrix

아래 표는 26개 항목 각각에 대해, 7개 서브셋에서 필요 필드를 갖춘 궤적의 비율 $p(\%)$ 를 실측한 전체 행렬이다. p 가 90 이상인 칸이 본문 Table 7의 판정가능에 해당한다. 값이 0과 100에 집중되는 것은 필드의 존재가 개별 궤적이 아니라 로그 형식의 속성이기 때문이며, 중간값을 갖는 칸(예: AEB GAIA의 L2 항목군 88, Who&When AG의 계획 항목군 48~53)이 임계값 민감도의 원천이 된다.

Table A1. Field-Availability Ratio $p(\%)$ per Item and Subset (실측)

항목	A-ALF	A-WS	A-GA	T-GA	T-SW	W-AG	W-HC
L0-01	100	100	100	100	100	100	100
L0-02	100	100	100	100	100	100	100
L0-03	100	100	100	0	0	0	0
L0-04	100	100	100	100	100	0	0
L0-05	0	0	0	0	0	100	100
L0-06	0	0	0	100	100	0	0
L0-07	0	0	0	100	100	0	0
L1-01	0	0	0	0	0	0	0
L1-02	77	0	0	100	100	0	0
L1-03	84	26	66	100	100	0	0
L1-04	100	100	92	100	100	0	0
L2-M1	100	100	88	100	100	100	100
L2-M2	100	100	88	100	100	100	100
L2-M3	100	100	88	100	100	87	100
L2-R1	100	100	88	6	0	97	88
L2-R2	100	100	88	6	0	85	88
L2-P1	100	100	94	0	0	53	100
L2-P2	100	100	94	0	0	48	100
L2-P3	100	100	94	0	0	53	100
L2-A1	100	100	88	0	0	52	100

L2-A2	100	100	92	100	100	0	0
L3-01	100	100	98	100	100	100	100
L3-02	100	100	98	100	100	100	100
L3-03	100	100	98	100	100	100	100
L3-04	100	100	88	0	0	51	88
L3-05	100	100	98	100	100	100	100

주: A=AgentErrorBench, T=TRAIL, W=Who&When.
ALF=ALFWorld, WS=WebShop, GA=GAIA, SW=SWE-Bench, AG=Algorithm-Generated, HC=Hand-Crafted.

References

- [1] L. Wang et al., "A Survey on Large Language Model based Autonomous Agents," *Frontiers of Computer Science*, Vol. 18, 186345, 2024.
- [2] S. Yao et al., "ReAct: Synergizing Reasoning and Acting in Language Models," *Proc. ICLR*, 2023.
- [3] K. Zhu et al., "Where LLM Agents Fail and How They Can Learn From Failures," *arXiv:2509.25370*, Sep. 2025.
- [4] D. Deshpande, V. Gangal, H. Mehta, J. Krishnan, A. Kannappan, and R. Qian, "TRAIL: Trace Reasoning and Agentic Issue Localization," *arXiv:2505.08638*, 2025.
- [5] S. Zhang et al., "Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems," *Proc. ICML (PMLR 267)*, 2025. *arXiv:2505.00212*.
- [6] NIST, "Artificial Intelligence Risk Management Framework (AI RMF 1.0)," NIST AI 100-1, Jan. 2023.
- [7] ISO/IEC 42001:2023, "Information technology — Artificial intelligence — Management system," ISO, 2023.
- [8] M. Cemri et al., "Why Do Multi-Agent LLM Systems Fail?," *arXiv:2503.13657*, 2025.
- [9] "AgentFail: Failure Analysis of LLM Agents in Real-World Deployments," *arXiv:2509.23735*, 2025. (서지 투고 전 확정)
- [10] "TraceElephant: Complete-Observation Traces for Agent Failure Attribution," 2026. (서지 투고 전 확정)
- [11] OpenTelemetry / Arize AI, "OpenInference: Semantic Conventions for AI Observability," <https://github.com/Arize-ai/openinference> (accessed 2026).
- [12] R. C. Nickerson, U. Varshney, and J. Muntermann, "A Method for Taxonomy Development and its Application in Information Systems," *European Journal of*

Information Systems, Vol. 22, No. 3, pp. 336-359, 2013.

- [13] A. R. Hevner, S. T. March, J. Park, and S. Ram, "Design Science in Information Systems Research," MIS Quarterly, Vol. 28, No. 1, pp. 75-105, 2004.
- [14] K. Peffers, T. Tuunanen, M. A. Rothenberger, and S. Chatterjee, "A Design Science Research Methodology for Information Systems Research," Journal of Management Information Systems, Vol. 24, No. 3, pp. 45-77, 2007.
- [15] J. R. Landis and G. G. Koch, "The Measurement of Observer Agreement for Categorical Data," Biometrics, Vol. 33, No. 1, pp. 159-174, 1977.
- [16] F. Rabanser et al., "Towards a Science of AI Agent Reliability," Proc. ICML, 2026. arXiv:2602.16666. (서지 투고 전 확정)
- [17] "AgentProcessBench: Diagnosing Step-Level Process Quality of Tool-Augmented Agent Trajectories," arXiv:2603.14465, 2026. (서지 투고 전 확정)
- [18] "TELBench: Span-Level Error Localization for Deep-Research Agent Trajectories," arXiv:2606.02060, 2026. (서지 투고 전 확정)
- [19] "REFLECT: Intervention-Supported Error Attribution for LLM Agent Traces," arXiv:2606.09071, 2026. (서지 투고 전 확정)
- [20] "Oat: Unsupervised Error Attribution for LLM Agents via One-Class Learning," arXiv:2607.12747, 2026. (서지 투고 전 확정)
- [21] "Conformal Agent Error Attribution," arXiv:2605.06788, 2026. (서지 투고 전 확정)
- [22] "AgenTracer: Tracing Failures in Multi-Agent Systems via Counterfactual Replay and Fault Injection," arXiv:2509.03312, 2025. (서지 투고 전 확정)

※ 참고문헌 [9], [10], [16]~[22]는 투고 전 원문 서지 재확인 필요. Authors 란은 투고 시 작성.