

LLM 에이전트 오류 진단 가능성 측정 방법론

A Methodology for Measuring Error Diagnosability of LLM Agents

000* · 김남규**

*국민대학교 비즈니스 IT 전문대학원 석사과정, **국민대학교 비즈니스 IT 전문대학원 교수, 교신저자

Abstract

Methods for automatically diagnosing failures of LLM-based agents are accumulating rapidly. Yet every diagnosis and attribution method operates on the premise that execution logs record the evidence required for judgment, and the extent to which this premise holds in real logs has never been measured. This study elevates the premise to a measurable property: diagnosability. By cross-mapping five error taxonomies and the failure-attribution and observability literature, we derive a four-layer, 26-item instrument in which each item is operationalized by a diagnostic question, required log fields, and an assessment mode; absence of required fields renders an item unassessable, which quantifies the diagnosability of a log. Applying the instrument to all 532 failure trajectories of three public benchmarks with heterogeneous log formats, we find that diagnosability is determined by log format rather than task (38.5–76.9%; the same GAIA tasks score 50.0% vs. 61.5% across formats), and that cognitive-module records and system-level records are complementarily missing across existing benchmarks. We further map the log evidence required by four coexisting error definitions, showing that the unrecoverable-failure definition is operationalizable in only two of seven subsets and the counterfactual definition in none from completed logs alone. These results imply that attribution accuracies computed under different definitions cannot be compared without reporting observation conditions and definitions together, and provide measured grounds for minimal logging design toward diagnosable agent systems.

Keyword: Diagnosability, LLM Agent, Execution Log, Failure Diagnosis, Error Taxonomy, Checklist

1. 서론

대규모 언어 모델(Large Language Model, LLM)을 추론 엔진으로 삼아 도구 호출과 다단계 의사결정을 수행하는 에이전트가 다양한 도메인에 도입되고 있다(Wang et al., 2024; Yao et al., 2023). 이에 따라 실패한 실행 궤적으로부터 원인을 자동으로 찾으려는 진단·귀인 방법 연구가 빠르게 축적되고 있다. 실패 귀인 과제의 정식화(Zhang et al., 2025) 이후 불과 1년여 사이에 모듈 분석 기반 진단(Zhu et al., 2025), 개입 기반 검증(REFLECT, 2026), 오류 주입과 반사실 재생 기반의 데이터 주도 접근(AgenTracer, 2025), 그리고 제약 합성 기반 진단(Barke et al., 2026)이 잇달아 제안되었으며, 실패 궤적과 정답 주석을 담은 공개 벤치마크도 다수 공개되었다(Deshpande et al., 2025; Ma et al., 2025).

그러나 이들 방법은 모두 하나의 암묵적 전제 위에서 작동한다. 실행 로그에 판정의 근거가 기록되어 있다는

전제다. 이 전제가 무너지는 때 방법이 어떻게 무력화되는지는 방법 연구들 스스로가 기록하고 있다. 최근의 진단 프레임워크인 AgentRx(Barke et al., 2026)는 도메인 정책이 없는 벤치마크에서 전역 제약을 합성하지 못해 해당 실험을 단일 도메인으로 한정하였고, 장문 궤적에서는 검증 신호가 희소해져 개선 폭이 소멸하였다. 완전 관찰 궤적이 부분 관찰 대비 귀인 정확도를 크게 개선한다는 보고(TraceElephant, 2026)와 단일 벤치마크 내부에서 정보 유형을 제거하는 절제 실험(Whole Elephant, 2026)도 같은 방향을 가리킨다. 그럼에도 이 전제 자체, 즉 로그가 어떤 판정까지 허용하는가를 이질적인 공개 데이터셋들을 가로질러 측정한 연구는 아직 확인되지 않는다.

전제는 하나 더 있다. 정답 주석이 가리키는 대상, 곧 오류의 구성개념이 연구 간에 동일하다는 전제다. 실제로는 최초 실패(Zhang et al., 2025), 최초의 복구 불가 실패(Barke et al., 2026), 교정 시

성공으로 전환되는 반사실적 결정 오류(Zhu et al., 2025; Ma et al., 2025), 그리고 자가 복구된 실수를 제외하는 정의(TELBench, 2026)의 네 가지 조작적 정의가 병존한다. AgentRx가 Who&When의 궤적 44건을 자체 정의로 재주석하였을 때 두 주석의 단계가 일치한 것은 16건이었다(Barke et al., 2026). 이 차이는 주석의 품질 문제가 아니라 정의의 차이에서 예측되는 귀결이지만, 정의 간의 관계는 정식화된 바 없고, 차이가 알려진 뒤에도 서로 다른 정의 위에서 산출된 정확도 수치들이 동일 지표처럼 비교되는 관행은 계속되고 있다.

성숙한 공학 분야들은 같은 국면을 같은 방식으로 통과하였다. 이산사건시스템 이론은 고장 진단 방법의 축적 이후에 진단가능성(diagnosability)을 시스템의 독립 속성으로 정식화하였으며(Sampath et al., 1995), 제어이론의 가관측성과 반도체의 검사용이성 설계가 그 선례다. 이에 본 연구에서는 이 경로를 에이전트 실행 로그에 적용하여, 진단가능성을 측정 가능한 속성으로 도입하는 방법론을 제안하고자 한다. 본 연구가 다루는 연구 질문은 다음 세 가지다. RQ1: 진단가능성을 실행 로그만으로 판정 가능한 측정 도구로 어떻게 조작화할 수 있는가? RQ2: 공개 벤치마크 로그의 진단가능성은 어느 수준이며, 무엇이 그것을 결정하는가? RQ3: 병존하는 오류 정의들은 각각 어떤 로그 증거를 요구하며, 현존 로그에서 어떤 정의가 조작화 가능한가?

본 연구의 기여는 세 가지다. 첫째, 오류 분류 체계 5종과 실패 귀인·관측가능성 문헌을 교차 대응하여 판정 질문, 필요 로그 필드, 그리고 판정 방식의 3요소로 조작화된 4계층 26항목 점검 도구를 도출하고, 필요 필드의 부재가 판정 불가로 이어지는 구조로 진단가능성을 정량화하는 방법을 제안한다(RQ1). 둘째, 이 도구를 공개 벤치마크 3종의 실패 궤적 532건 전수에 적용하여, 진단가능성이 과제가 아니라 로그 형식에 의해 결정되고 인지 기록과 시스템 기록이 상보적으로 누락되어 있음을 실측하며, 오류 정의의 4종의 요구 증거를 사상하여 정의의 채택 가능성 자체가 관측 조건에 제약됨을 보인다(RQ2, RQ3). 셋째, 실측에서 역산되는 최소 로깅 설계의 근거와, 귀인 성능 보고에 관측 조건과 오류 정의를 함께 적는 보고 관행의 근거를 제시한다. 본 연구는 기존 진단 방법들과 경쟁 관계가 아니라 직렬 관계에 있다. 진단가능성 점검을 통과한 로그에 자동 진단을 적용하는 구성이 본 연구가 제안하는 구도다.

본 논문의 이후 구성은 다음과 같다. 제 2 장에서는 에이전트 실행 궤적, 오류 분류 체계, 자동 실패 귀인,

그리고 관측·진단 인프라에 관한 선행 연구를 고찰한다. 제 3 장에서는 본 연구에서 제안하는 진단 체크리스트 도출 방법론을 소개하고, 제 4 장에서는 제안 도구를 공개 벤치마크에 적용한 실험의 과정과 결과를 소개한다. 마지막 제 5 장에서는 본 연구의 기여와 한계, 그리고 향후 연구의 방향을 정리한다.

2. 선행 연구

2.1 LLM 에이전트와 실행 궤적

LLM 에이전트는 프로파일, 메모리, 계획, 그리고 행동의 모듈로 구성되는 것이 표준적 구도이며(Wang et al., 2024), 실행 시 각 단계는 환경 관찰(observation)을 입력으로 모듈들을 순차 통과하여 행동을 산출한다(Yao et al., 2023). 이 과정의 기록이 실행 궤적으로, 단계 인덱스, 모듈별 출력(메모리 회상, 반성, 계획, 행동), 환경 피드백 등의 필드로 구성된다. 궤적의 기록 수준은 시스템마다 서로 다르며, 완전 관찰(complete observation) 궤적이 부분 관찰 대비 오류 귀인 정확도를 크게 개선한다는 보고(TraceElephant, 2026)는 로그에 무엇이 기록되어 있는가가 진단의 상한을 규정함을 시사한다. 산업 현장에서는 OpenTelemetry 기반의 스패(span) 표준이 에이전트 관측 형식으로 확산되고 있다(Deshpande et al., 2025; OpenTelemetry, 2025).

2.2 에이전트 오류 분류 체계

에이전트 오류 분류 체계는 제안 관점에 따라 세 갈래로 나뉜다. 첫째, 관찰자 관점의 분류로, TRAIL(Deshpande et al., 2025)은 GAIA와 SWE-bench 트레이스 148건의 오류 841개를 추론 오류, 시스템 실행 오류, 그리고 계획·조정 오류의 3대분류 아래 주석하였다. 둘째, 아키텍처 관점의 분류로, AgentErrorTaxonomy(Zhu et al., 2025)는 메모리, 반성, 계획, 행동, 그리고 시스템의 5개 모듈에 17개 오류 유형을 배치하고 실패 롤아웃 200건의 AgentErrorBench를 공개하였으며, AgentRx(Barke et al., 2026)는 근거 이론 코딩으로 교차 도메인 9개 범주를 도출하였다. 셋째, 시스템·현장 관점의 분류로, MAST(Cemri et al., 2025)는 멀티에이전트 시스템의 실패 유형 14개를 정리하였고, AgentFail(Ma et al., 2025)은 로우코드 플랫폼(Dify, Coze)의 실서비스 실패 307건을 에이전트, 워크플로, 그리고 플랫폼의 3수준 16유형으로 분류하고, 주석대로 수리하면 실행이 실제로 성공하는지 확인하는 반사실 수리 실험으로 주석의

신뢰성을 검증하였다. 이들 분류 체계는 각자의 무대에서 검증되었으나 상호 사상은 시도된 바 없으며, 최근 단계 수준 주석의 대규모화 (AgentProcessBench, 2026; TELBench, 2026)가 이어지면서 분류와 형식의 파편화는 오히려 심화되고 있다.

2.3 자동 실패 귀인과 오류의 조작적 정의

Zhang et al.(2025)은 실패 로그로부터 책임 에이전트와 결정적 오류 단계를 자동 식별하는 과제를 자동 실패 귀인(automated failure attribution)으로 정식화하고 주석 데이터셋 Who&When 을 공개하였다. 이후 개입 기반 검증(REFLECT, 2026), 비지도 귀인(Oat, 2026), 오류 주입과 반사실 재생 기반의 데이터 주도 접근(AgenTracer, 2025), 그리고 도구 스키마와 도메인 정책으로부터 제약을 합성해 위반 로그를 생성하고 LLM 판정자가 이를 근거로 진단하는 AgentRx(Barke et al., 2026)가 제안되었다. 분류 체계를 판정 프롬프트에 제공하는 것만으로 근본원인 식별 정확도가 8.3~13.0%에서 24.1~33.6%로 상승하고(Ma et al., 2025), 분류 체계에 근거한 판정 기준선이 기존 귀인 방법을 능가한다는 보고(Barke et al., 2026)는, 연구용 분류를 판정 가능한 점검 항목으로 조작화하는 방향이 자동 판정의 성능 기반이 됨을 시사한다.

한편 이들 연구가 정답으로 삼는 오류의 조작적 정의는 단일하지 않다. 네 정의가 병존한다. 첫째, 최초 실패(first failure)로, Who&When(Zhang et al., 2025)은 실패로 이어진 오류가 처음 나타난 단계를 주석한다. 둘째, 최초의 복구 불가 실패(first unrecoverable failure)로, AgentRx(Barke et al., 2026)는 이후 단계에서 복구된 실패를 제외하고 복구되지 못한 최초의 실패를 결정적 단계로 정의한다. 셋째, 반사실적 결정 오류(counterfactual decisive error)로, AgentDebug(Zhu et al., 2025)와 AgentFail(Ma et al., 2025)은 해당 단계를 교정하면 실행이 성공으로 전환되는 가장 이른 오류를 채택한다. 넷째, 자가 복구 제외 정의로, TELBench(2026)는 정상적 탐색과 자가 복구된 실수를 오류에서 제외한다. AgentRx가 Who&When의 Magentic 궤적 44건을 자체 정의로 재주석하였을 때 단계가 일치한 것은 16건이었으며(Barke et al., 2026), 이는 정의가 다른 두 측정이 다른 값을 내는 예측된 귀결이다. 그러나 네 정의의 상호 관계와 일치 조건은 정식화된 바 없으며, 정의 차이가 알려진 뒤에도 서로 다른 정의 위의 정확도들이 동일 지표처럼 비교되는 관행이 계속되고

있다. 본 연구는 제 3장의 도구에 이 정의들을 요구 증거로 환원하는 사상을 포함시켜, 어떤 정의가 어떤 로그에서 조작화 가능한지를 제 4장에서 실측한다.

2.4 관측·진단 인프라 연구

진단의 전제인 관측 조건에 접근한 연구는 최근에만 나타나고 있다. 관측 구성을 실험 변수로 도입한 벤치마크(Whole Elephant, 2026)는 메타데이터나 입력을 제거한 조건에서 귀인 정확도의 변화를 절제 실험으로 측정하였고, AgentDebugX(Zhu et al., 2026)는 재분석과 비교를 위한 이식성 있는 프레임워크 불문 트레이스 스키마를 제안하였으며, 멀티에이전트 시스템에 실패 인지적 관측가능성(failure-aware observability)이 필요하다는 주장(Failure-Aware Observability, 2026)도 제기되었다. 그러나 절제 실험은 단일 벤치마크 내부의 측정이어서 로그 형식 간 비교가 불가능하고, 스키마 제안은 어떤 필드가 왜 필요한지의 측정 근거를 결여한다. 절제와 규격 제안 사이의 빈 자리, 곧 이질 형식을 가로지르는 계측이 본 연구의 위치이며, 이는 방법 연구가 아니라 측정 도구 연구로서 기존 진단 방법들과 직렬 관계에 있다.


2.5 분류 체계 개발 방법론과 설계과학

정보시스템 분야에서 분류 체계와 점검 도구의 개발은 확립된 방법론 전통을 갖는다. Nickerson et al. (2013)은 개념에서 경험으로, 경험에서 개념으로의 반복 사이클과 사전 정의된 종료 조건을 통해 분류 체계를 도출하는 표준 절차를 제시하였으며, 설계과학 연구(Design Science Research)는 문헌 기반으로 인공물(artifact)을 설계하고 실제 문제への 적용과 시연으로 유용성을 평가하는 연구 양식을 정당화한다(Hevner et al., 2004; Peffers et al., 2007). 인공물 판정의 신뢰성은 내용분석의 전통에 따라 복수 평가자의 독립 코딩과 Cohen의 카파 계수로 검증할 수 있으며, 그 해석에는 Landis and Koch(1977)의 기준이 통용된다(Cohen, 1960). 실제로 에이전트 오류 분류 체계 연구들 또한 전문가 델파이가 아닌 문헌과 데이터 기반의 도출과 주석자 간 일치도 보고의 방식을 취하고 있어(Zhu et al., 2025; Deshpande et al., 2025; Cemri et al., 2025), 본 연구의 접근은 해당 분야의 방법론 관행과 일치한다.

3. 제안 방법론

3.1 연구 절차

본 연구의 체크리스트 도출 절차는 Nickerson et al. (Nickerson et al., 2013)의 분류 체계 개발 방법을 점검 도구 개발에 맞게 확장한 것으로, [그림 1]과 같이 6 단계로 구성된다: ① 점검 대상·단위 확정 → ② 소스 코퍼스 구축 → ③ 항목 후보 전수 추출 → ④ 교차 대응·병합 → ⑤ 조작화(질문·필드·방식) → ⑥ 파일럿 적용·반복 정제. 절차 전반의 설계 원칙은 두 가지다. 첫째, 추적가능성(traceability): 모든 최종 항목은 어느 문헌의 어느 개념에서 왔고 어떤 병합 결정을 거쳤는지 역 추적 가능해야 한다. 둘째, 판정가능성(assessability): 모든 항목은 분류 명칭이 아니라, 제3자가 실행 로그만으로 답할 수 있는 판정 질문의 형태여야 한다. 각 단계의 세부 프로세스는 본 장의 이후 절에서 상세히 설명하며, 도출된 도구를 실제 데이터에 적용한 실험의 과정과 결과는 제 4 장에서 제시한다.



[그림 1] 연구 전체 프로세스

Step 1 (점검 대상·단위 확정). 점검 대상은 단일 에이전트의 실행 로그 1 건, 점검 주체는 시스템 내부 구현을 알지 못하는 제3자 진단자, 판정 산출은 항목별 {예 / 아니오 / 판정불가}와 근거 위치(단계 또는 스패)로 정의한다. 멀티에이전트 고유 현상은 본 버전의 범위에서 제외하되, 제외 목록으로 보존하여 후속 버전의 확장 지점으로 남긴다.

3.2 소스 코퍼스 구성

Step 2. 소스 문헌은 다음 포함 기준으로 선정하였다: (i) 에이전트 오류의 유형 체계 또는 진단·귀인의 차원을 명시적으로 제안하고, (ii) 공개 데이터 또는 재현 가능한 주석 절차를 동반하며, (iii) 2024 년 이후 발표된 문헌. 이 기준에 따라 오류 분류 체계 4 종과 보조 문헌군(귀인 정의, 관측가능성, 신뢰성 지표)으로 코퍼스를 구성하였으며, 그 내역은 <표 1>과 같다.

<표 1> 체크리스트 도출을 위한 소스 코퍼스

구분	문헌	관점/단위	본 연구에서의 역할
분류 체계	AgentErrorTaxonomy (Zhu et al., 2025)	아키텍처(5 모듈·17 유형), 결정 단계	L2 단계 오류 항목의 근간
분류 체계	TRAIL (Deshpande et al., 2025)	관찰자(3 대분류), OTel 스패	L1·L2 항목 보강, 영향도 개념
분류 체계	MAST (Cemri et al., 2025)	MAS 실패 14 유형	L2·L3 보강, MAS 전용 유형의 제외 목록
분류 체계	AgentFail (Ma et al., 2025)	실서비스 실패 307 건	시스템·환경 오류 항목의 현장 타당성 확인
분류 체계	AgentRx (Barke et al., 2026)	교차 도메인 9 범주	도출 후 외부 포화 확인 (3.5 절), 오류 정의 D2의 출처
귀인	Who&When (Zhang et al., 2025)	결정적 오류 단계 정의	L3 제적 항목(최초 오류 위치)의 근거
관측	완전 관찰 제적 연구 (TraceElephant, 2026), OTel(2025)	기록 수준, 스패 구조	L0 관측가능성 항목의 근거
신뢰성	에이전트 신뢰성 지표 연구 (Rabanser et al., 2026)	일관성·강건성 차원	L3 반복성 항목의 개념 근거

주: 각 문헌의 서지 정보는 참고문헌 참조. 코퍼스 선정 과정에서 제외된 문헌과 제외 사유는 부속 저장소에 기록한다.

3.3 항목 추출과 분류 체계 간 교차 대응

Step 3 (전수 추출). 코퍼스의 각 문헌에서 오류 유형·차원·지표를 병합 없이 전수 추출하였다. 추출 레코드는 {식별자, 원문 용어, 정의 요지, 출처, 수준(단계/모듈/제적/시스템)}의 5 요소로 구성되며, 분류 체계 4 종에서 총 46 개의 원 개념이 추출되었다 (AgentErrorTaxonomy 17, TRAIL 15, MAST 14 및 보조 문헌의 차원 개념).

Step 4 (교차 대응·병합). 추출된 개념들을 대상으로 동일 현상 여부를 판정하여 병합·제외하는 사상 작업을

수행하였다. 판정의 자의성을 통제하기 위해 다음의 병합·제외 규칙을 사전에 선언하였다.

R1 (관찰 동치 병합): 실행 로그상에서 구별되는 관찰 증거를 제시할 수 없는 두 개념은 하나의 항목으로 병합한다.

R2 (범위 제외): 멀티에이전트 상호작용을 전제하는 개념은 제외하되, 제외 목록으로 보존한다.

R3 (탐지 방식 재배치): 규칙 기반으로 완전 탐지 가능한 개념은 LLM 판정이 필요한 오류 층(L2)이 아니라 실행 층(L1)으로 배치한다.

R4 (구조 분리): 단계 수준 현상과 궤적 수준 현상이 혼합된 개념은 두 항목으로 분리한다.

사상 결과의 발체는 <표 2>와 같다. 전체 46 개 원 개념 중 31 개가 21 개 통합 개념으로 병합되었고, 9 개가 R2 에 의해 제외되었으며, 6 개는 판정 불가능(로그 외 정보 요구)으로 제외되었다.

<표 2> 분류 체계 간 교차 대응 (발체)

통합 개념	AgentError Taxonomy (Zhu et al., 2025)	TRAIL (Deshpande et al., 2025)	MAST (Cemri et al., 2025)	결정	항목
기억 환각	Memory: Hallucination	Language-only Hallucination	—	병합	C-M1
검색 실패	Memory: Retrieval Failure	Poor Information Retrieval	Loss of Conv. History	병합	C-M2
요약 과잉단순화	Memory: Oversimplification	—	—	단독	C-M3
진행 오판	Reflection: Progress Misjudge	—	Unaware of Term. Cond.	병합	C-R1
결과 오독	Reflection: Outcome Misinterp.	Tool Output Misinterp.	Incorrect Verification	병합	C-R2
인과 오귀속	Reflection: Causal Misattr.	—	—	R1: C-R1에 병합	(C-R1)
제약 무시	Planning: Constraint Ignorance	Instruction Non-compliance	Disobey Task Spec.	병합	C-P1
불가능 행동 계획	Planning: Impossible Action	Incorrect Problem ID (인접)	—	병합	C-P2
비효율 계획	Planning: Inefficient	Resource Abuse (부분)	Step Repetition	병합 +R4	C-P3,

	Plan		(부분)	분리	C-T5
계획-행동 불일치	Action: Misalignment	—	Reasoning-Action Mismatch	병합	C-A1
파라미터 오류	Action: Parameter Error	Tool Selection Error (인접)	—	병합	C-A2
형식 무효 행동	Action: Format Error	Formatting Errors	—	병합, R3: L1 재배치	C-S2
스텝 한도 소진	System: Step Limit	Resource Exhaustion	Premature Term. (역방향)	병합, R3	C-S1
환경·도구 실행 오류	System: Env./Tool Exec.	API Issues / Service Errors	—	병합, R3	C-S3
최초·결정적 오류	Critical Error (AET)	—	—	Who&When 정의 채택	C-T1
대화 재설정·정보 은폐 등	—	—	Conversation Reset 외 8 유형	R2: 제외 (MAS 전용)	제외


주: 전체 대응표(46 개 원 개념 × 결정 근거)는 부속 저장소로 제공한다. "인접"은 완전 동일하지 않으나 로그 관찰상 구별 실익이 없어 R1 을 적용한 경우를 뜻한다.

3.4 조작화

Step 5. 통합 개념을 실무 점검 항목으로 변환하기 위해 각 개념을 다음 3 요소로 재정의하였다. (i) 판정 질문: 예/아니오로 답해지는 문장. (ii) 필요 로그 필드: 판정에 요구되는 증거 필드의 명세. (iii) 판정 방식: 규칙 기반 자동(R), LLM 판정(L)의 구분 — 본 개정판은 인간 확정 단계를 제거하고 LLM 단독 판정 체계를 채택하였다(신뢰성 대리 지표는 제 4.4 절). 이 구조의 핵심 설계는 필요 필드가 로그에 부재할 경우 해당 항목이 자동으로 '판정불가'가 되도록 한 것이다. 이에 따라 어떤 로그의 판정가능 항목 비율이 곧 그 로그의 진단가능성 점수로 도출되며, 관측가능성 점검(L0)이 별도 설계 없이 체크리스트 구조 자체에서 파생된다. 필드 존재는 두 수준으로 구분한다. 구조 필드(E, explicit)는 스키마상 분리되어 기록된 필드를 의미하며, 매몰 근거(B, embedded)는 별도의 필드는 존재하지 않으나 자유텍스트 안에 판정 근거가 포함된 경우로서 사전에 선언된 패턴으로 검출한다. 판정 방식이 R 인 항목은 규칙이 자유텍스트를 신뢰성 있게 해석할 수 없으므로 E 를 요구하고, L 인 항목은 LLM 이 자유텍스트를 판독할 수 있으므로 B 를

허용하며, R과 L의 복합 항목은 R 성분의 필드에 E를 요구한다. 이러한 요구 수준 규칙이 없으면 발화형 로그의 커버리지가 형식 차이만으로 급락하여 벤치마크 간 비교 자체가 어려워진다.

항목은 4개 계층으로 조직하였다([그림 2]). L0은 판정의 전제가 되는 기록 존재 여부(7 항목), L1은 에이전트 추론 외적 실패의 분리(4 항목), L2는 모듈별 단계 오류의 존재(10 항목), L3은 궤적 수준의 구조적 특성(5 항목)을 다룬다. 계층 간에는 의존 관계가 성립한다 — L0의 특정 항목이 '아니오'이면 이를 필요 필드로 삼는 하위 항목들은 판정불가가 된다. 최종 체크리스트 26 항목의 전체 내역은 <표 3>과 같다. 초기 도출본의 L3-06(복합 오류 연쇄)은 판정회의를 전제한 항목으로, 본 개정판의 LLM 단독 판정 체계(제 4장)와 양립하지 않아 삭제하고 v2 과제로 이관하였다.



[그림 2] 체크리스트의 4 계층 구조

<표 3> 도출된 진단 체크리스트 (4 계층 26 항목)

ID	판정 질문	필요 로그 필드	방식	도출 근거
L0-01	과제 명세(목표·제약)가 로그에 포함되는가	task specification	R	W&W, TrE
L0-02	단계 경계가 명확히 식별되는가	step index	R	AET, OTeI
L0-03	모듈 출력이 단계마다 구분 기록되는가	module tags	R	AET
L0-04	환경 관찰이 각 행동 뒤에 기록되는가	observation	R	AET, TrE
L0-05	최종 성패 판정과 근거가 기록되는가	outcome label	R	W&W
L0-06	도구/API 원시 응답이 별도 보존되는가	raw tool response	R	TRAIL, TrE
L0-07	시스템 메타데이터(모델·토큰·지연)가 기록되는가	system metadata	R	TRAIL, OTeI
L1-01	스텝 한도 소진으로 종결되는가 (C-S1)	step index, 한도 설정	R	AET, TRAIL, MAST
L1-02	형식상 무효 행동이 발생하는가 (C-S2)	action, env. error msg	R	AET, TRAIL
L1-03	환경·도구 실행 오류가 관측되는가 (C-S3)	observation, error msg	R+L	AET, TRAIL, AgentFa

				il
L1-04	동일 무효 행동이 교정 없이 반복 (≥3 회)되는가	action sequence	R	MAST
L2-M1	이전 기록에 없는 사실을 회상하는가 (C-M1)	memory, 전 단계 이력	L	AET, TRAIL
L2-M2	기록에 있는 정보를 회상하지 못하는가 (C-M2)	memory, 전 단계 이력	L	AET, TRAIL, MAST
L2-M3	요약이 과제 관련 핵심 세부를 누락하는가 (C-M3)	memory, observation	L	AET
L2-R1	진행 상황을 과대/과소평가하는가 (C-R1)	reflection, outcome	L	AET, MAST
L2-R2	직전 관찰 결과를 잘못 해석하는가 (C-R2)	reflection, observation	L	AET, TRAIL, MAST
L2-P1	과제 제약과 모순되는 계획을 세우는가 (C-P1)	plan, task spec.	L	AET, TRAIL, MAST
L2-P2	전제조건상 불가능한 행동을 계획하는가 (C-P2)	plan, observation 이력	L	AET
L2-P3	동일 전략 고수·탐색 낭비가 지속되는가 (C-P3)	plan sequence	L	AET, TRAIL, MAST
L2-A1	행동이 직전 계획과 불일치하는가 (C-A1)	plan, action	L	AET, MAST
L2-A2	행동 인자·대상 지정이 잘못되는가 (C-A2)	action, observation	R+L	AET, TRAIL
L3-01	최초 오류 단계가 특정되는가 (C-T1)	L2 판정 결과 전체	L	W&W, AET
L3-02	최초 오류의 위치(초/중/종반)는 어디인가	L3-01, step index	R(파생)	W&W
L3-03	최초 오류→종결의 전파 길이는 얼마인가	L3-01, step index	R(파생)	AET
L3-04	최초 오류 이후 자기 교정 시도가 있는가	reflection, plan 변화	L	AET
L3-05	동일 오류 유형이 반복(≥2 회)되는가 (C-T5)	L2 판정 결과 전체	R(파생)	(Cemri et al., 2025), (Rabanser et al., 2026)

주: "R(파생)"은 선행 항목의 판정 결과로부터 규칙적으로 계산되는 항목. 각 항목의 상세 판정 지침(긍정/부정 예시 포함)은 코딩 매뉴얼로 별도 제공한다.

3.5 반복 정제와 종료 조건

Step 6. 도출된 체크리스트는 대상 데이터의 표본(벤치마크별 5~10 건)에 파일럿 적용한 뒤 문항 모호성, 항목 간 중복 판정, 과도한 판정불가를 점검하여 개정하는 반복 사이클을 거친다. 반복의 종료 조건은 Nickerson et al.(Nickerson et al., 2013)을 따라

사전 선언하였다: (i) 표본의 모든 관측 오류가 항목 중 하나에 분류되고, (ii) 하나의 관측 증거가 두 항목에 동시에 해당하는 사례가 없으며, (iii) 마지막 반복에서 항목의 추가·삭제·문구 변경이 발생하지 않을 것. 본 버전(v0.1)은 2 회의 파일럿 반복을 거쳐 상기 조건을 충족하였으며, 변경 이력은 버전 로그로 보존한다.

아울러 체크리스트 확정 이후 공개된 분류 체계 2 종을 대상으로 종료 조건의 외부 확인을 수행하였다. AgentRx(Barke et al., 2026)의 9 개 범주와 AgentFail(Ma et al., 2025)의 16 개 유형을 26 항목에 사상한 결과, 단일 에이전트 범위의 유형은 두 가지 예외를 제외하고 전부 기존 항목에 흡수되었다. 예외는 과제 명세의 품질 차원을 다루는 Underspecified User Intent(Barke et al., 2026)와 실행 로그가 아닌 시스템 구성의 결함인 프롬프트 설계 결함(Ma et al., 2025)으로, 전자는 L0-01의 확장 논점으로, 후자는 범위 밖 항목으로 각각 후속 버전(v2)의 과제에 기록하였다. 도출 이후의 독립적인 분류 체계가 새 항목을 요구하지 않는다는 이 결과는 이론적 포화의 외부 증거로 해석될 수 있으며, 전체 대응 내역은 부속 저장소에 공개한다.

4. 실험

4.1 실험 개요

본 장에서는 도출된 도구를 공개 벤치마크에 적용한 실험의 데이터, 처리 절차, 산출값, 그리고 해석을 제 3자가 그대로 재현할 수 있는 수준으로 명세한다. 실험은 네 부분으로 구성된다. 첫째, 진단가능성 커버리지 측정(4.3 절, RQ2)은 규칙 기반 스크립트로 3 개 벤치마크 전수의 관측 조건을 측정하며, LLM 을 사용하지 않으므로 비용이 발생하지 않는다. 둘째, 판정 안정성 검증(4.4 절)은 인간 이중 코딩을 대체하는 세 가지 대리 지표(이중 모델 간 일치, 프롬프트 변형 자기 일관성, 그리고 정답 주석 적합)를 산출한다. 셋째, 오류 분포 산출과 판정 모델 민감도 측정(4.5 절)은 LLM 판정으로 항목별 오류 발생 비율과 모델 특성을 측정한다. 넷째, 오류 정의의 조작화 가능성 분석(4.6 절, RQ3)은 제 2.3 절의 오류 정의 4 종을 요구 로그 증거로 환원하고 커버리지 측정의 필드 가용률 행렬로 정의별 채택 가능성을 판정하는 분석으로, 역시 비용이 없다. 본 논문에서 커버리지 측정, 정의 조작화 분석, 정답 주석 기반 분포 통계, 그리고 판정 파일럿 9 건은 실측이 완료된 수치이며, LLM 실행이 필요한 판정 안정성과 오류 분포의 수치는 설계 목표를 예시한 가상 결과로서 해당 표의 캡션에 명기하고 실행 후 실측으로 교체한다. 실험 구성의 요약은 <표 4>, 실험 환경은 <표 5>와

같으며, 전 과정의 난수 시드는 20260817 로 고정하고 판정 프롬프트 전문과 산출 스크립트, 그리고 필드 가용률 행렬 전체는 부속 저장소에 공개한다.

<표 4> 실험 구성 요약

구분	내용
벤치마크	AgentErrorBench 전수 200 건(ALFWorld 100·WebShop 50·GAIA 50; GitHub: ulab-uiuc/AgentDebug, 데이터는 저자 Google Drive) · Who&When 전수 184 건(AG 126·HC 58; GitHub: mingyin1/Agents_Failure_Attribution) · TRAIL 전수 148 건(GAIA 117·SWE 31; HuggingFace: PatronusAI/TRAIL, 게이트 동의 필요) — 총 532 실패 궤적
표본추출	표본 없이 전수 사용. 프롬프트 변형 자기 일관성만 시드 20260817 의 20% 증화 표본
판정 모델	동일 계열 상위(Claude Sonnet 급)/저가(Claude Haiku 급), temperature 0, JSON 출력 강제, 스키마 위반 시 1 회 재시도. 동일 계열 상·하위 비교로 토크나이저·정렬 차이 교란을 통제
판정 인력	인간 코딩 없음(LLM 단독) — 신뢰성은 판정 안정성 검증의 3 중 대리 지표로 확보
SW	Python 3.12, 결과는 JSON Lines(traces.jsonl, judgments.jsonl, results/*.csv)로 버전 관리
예산(실측 건적)	532 건 × 모듈군 5 분할 = 2,660 쿼리/모델, 입력 약 14.5M 토큰(여유율 1.2 시 17.4M). 2 모델 전수 + 변형 표본: 표준 API 약 \$128, 배치 API 약 \$64 (2026-08 표준 단가 기준)

<표 5> 실험 환경

구분	항목	내용
SW	Python	3.12 (표준 라이브러리 + pyarrow: TRAIL parquet 파싱)
	산출 스크립트	정규화, 커버리지 계산, 분포 계산, 정의 사상의 4 종 (전 산출 결정)
판정 API	상위 모델	claude-sonnet-4-6 (temperature 0)
	저가 모델	claude-haiku-4-5 (temperature 0)
공통	난수 시드 / HW	20260817 고정 / 일반 CPU 환경 (규칙 기반 산출은 GPU 불요)

4.2 데이터 취득과 전처리

세 벤치마크는 로그 형식이 서로 다르므로(모듈 태그 텍스트 / 발화 히스토리 JSON / OTel 스패ن), 모든 궤적을 공통 중간 표현으로 정규화한 뒤 이후 단계를 수행한다. 공통 스키마는 {trace_id, task, steps[{idx, module_outputs{memory, reflection, plan, action}, observation, raw_tool_response, meta}], outcome, gold{critical_step, module, type}} 의 JSON Lines 이며, 벤치마크별 필드 매핑은 <표 6>와 같다. 원본에 없는 필드는 null 로 두며 삭제하지 않는다 — null 의 분포 자체가 커버리지 측정의 대상이기 때문이다. 전처리 규칙: (i) 단계 경계는 원본의 명시 인덱스를 우선하고, 없으면 발화 턴/스팬 트리 순서로 부여, (ii) 모듈 태그는 원본 구분자([Memory] 등,

plan/thought 필드, 스패 속성)를 파서로 추출하고 파싱 실패는 meta.parse_error 로 기록, (iii) 전처리 산출물은 벤치마크당 1 개의 traces.jsonl 로 저장하고 원본 대비 건수·단계수 합계를 검증 로그로 남긴다.

<표 6> 공통 스키마로의 필드 사상

공통 필드	AgentErrorBe nch	Who&When	TRAIL
task	과제 지시문	question(+GT)	루트 스패 입력
steps.idx	명시 step	history step	스패 순서(트리 평탄화)
module_outputs	모듈 태그 4 종(E)	구조 필드 없음 — 발화 내 매물 근거(B)만 패턴 검출	스패는 컴포넌트 구분 — 인지 모듈 태그 아님(B)
observation	환경 피드백	타 에이전트 발화(구분 표기)	도구 출력 스패
raw_tool_response	null(관찰이 프롬프트 템플릿에 포섭)	null	logs.body(E)
meta(모델·토큰·지연)	모델·스텝수만(부분, B)	null	duration-timestamp-service(E)
gold	critical step(1-based→0-based 변환)/module/ty pe	mistake_agent/step(0-based)/reason	errors[].location(span_id→DFS 인덱스)/category — 다중 오류는 최초 위치 채택

주: Who&When 의 발화 content 는 구조 필드(E)로 간주하지 않되, L 방식 항목에 한해 매물 근거(B)로 인정한다(1 제 2 장 요구 수준 규칙). 인덱싱은 세 벤치마크 모두 0-based 로 통일하였고(AEB 원본은 1-based 임을 전수 검증 후 변환), AEB GAIA 1 건은 골드 단계가 궤적 범위를 초과하여 본포 통계에서 제외하였다.

4.3 진단가능성 커버리지 측정

절차: traces.jsonl 에 대해 규칙 기반 스크립트가 26 개 항목 각각의 필요 필드 존재를 궤적 단위로 검사한다. 필드 요구 수준은 1 제 2 장의 규칙(R→E 필수, L→B 허용, R+L 은 R 성분 에 E)을 따르고, 매물 근거(B)의 검출 패턴은 사전 선언 후 부속 저장소에 공개한다. 항목의 벤치마크 수준 판정은 필드 충족 궤적 비율 $p \geq 0.9$ 이면 "판정가능", 아니면 "판정불가"이며, 해당 개념이 환경에 애초에 존재하지 않으면 "N/A"로 본문에서 제외한다(본 실측에서 N/A 는 발생하지 않았다). 진단가능성 점수 = 판정가능 항목 수 / (26 - N/A 수). 파생 항목(L3-02·03·05)은 입력 항목이 판정가능하고 단계 인덱스가 E 일 때 판정가능으로 정의한다. 이 실험은 LLM 을 쓰지 않으므로 비용 0 이며, 실측은 3 개 벤치마크 전수 532 건에 대해 완료되었다.

4.4 판정 안정성 검증

본 절에서는 판정 안정성의 검증 설계를 소개한다. 본 개정판은 인간 이중 코딩을 제거하고 세 가지 대리 지표를 사용한다. 첫째, 이중 모델 간 일치이다. 동일 계열의 상위 모델과 저가 모델을 독립적인 평가자처럼 두고, 전수 판정 결과에 대해 항목군별 κ 를 산출한다. 둘째, 프롬프트 변형 간 자기 일관성이다. 문항 순서를 뒤집고 지시문을 다시 서술한 변형 프롬프트로 상위 모델을 20% 증화 표본에 재판정시켜 원 판정과 일치율을 측정한다. 셋째, 정답 주석과의 정합이다. 원 벤치마크의 인간 주석(결정적 오류 단계와 모듈)과 LLM 의 L3-01 판정을 대조한다. 새로운 수작업 없이 인간 기준점을 유지하는 것이 이 설계의 핵심이다. 발생 비율이 낮은 항목에서는 κ 가 과소평가되므로 Gwet 의 AC1 을 함께 보고한다.

<표 7> 층위별 판정 안정성 (가상 결과 — 설계 목표 예시, 실행 후 실측 교체)

층	항목 수	모델 간 일치율	모델 간 κ
L0 Observability	7	0.99	0.97
L1 System & Execution	4	0.97	0.90
L2 Memory / Reflection	5	0.86 / 0.83	0.61 / 0.55
L2 Planning / Action	5	0.85 / 0.90	0.58 / 0.66
L3 Trajectory	5	0.87	0.64

<표 7>의 수치는 원 분류 체계의 인간 주석 일치도(모듈 기준 $\kappa=0.55$ (Zhu et al., 2025))를 준거로 한 설계 목표이며 실측이 아니다. 실측된 근거로는 판정 파일럿이 있다. 정답 주석과 격리된 상태에서 심사자가 벤치마크 3 종의 9 건(짧은 궤적 우선)을 판정한 뒤 정답과 대조한 결과, 결정적 오류 단계는 정확 일치 4/9, 오차 1 단계 이내 5/9, 그리고 오차 3 단계 이내 8/9 로 근접 판정이 지배적이었고, Who&When 의 오류 에이전트 지목은 4 건 모두 일치하였다. 반면 AEB 의 오류 모듈 일치는 1/5 에 그쳤는데, 정답이 memory 계열의 과잉단순화 유형에 집중된 반면 심사자는 근본 원인에 해당하는 모듈(행동 형식, 계획 오류)을 지목하는 체계적인 관점 차이가 관찰되었다. 이는 원 벤치마크 주석 자체의 중등도 일치($\kappa=0.55$)와 부합하는 현상으로 해석될 수 있으며, 정답 정합 지표는 단계(오차 k 단계 이내 허용) 중심으로 보고하고 모듈 일치는 보조 지표로 활용하는 것이 타당함을 시사한다.

<표 8> 최초 오류 단계(L3-01)의 정답 정합 (파일럿 행은 실측, 판정 모델 행은 실행 시 대체)

판정 주체	데이터	exact	±1	±3	±5
기준 보고 (Zhang et	Who&When	12.5~2	-	-	43.1

al., 2025) (참고)		5.5			
상위 모델 판정	3 개 벤치마크 전수	(실행 시)			
저가 모델 판정	3 개 벤치마크 전수	(실행 시)			
판정 파일럿 (실측, n=9)	3 개 벤치마크 혼합	44.4	55.6	88.9	-

주: 본 표의 목적은 항목 판정의 타당성 검증(정답 정합)이며, 참고로 함께 적은 기존 귀인 방법의 수치는 과제 정의가 서로 달라(단일 지목 대 26 항목 중 1 항목) 직접 비교에는 한계가 있다. 실행 시에는 전체 수치를 함께 벤치마크별 분해(서브셋 단위의 exact 와 $\pm k$)를 보고한다.

4.5 오류 분포 산출과 판정 모델 민감도

본 절에서는 오류 분포 산출과 판정 모델 민감도 측정의 절차를 소개한다. 파이프라인은 다음과 같다. 첫째, LLM 판정 단계에서는 532 건 전수에 대해 궤적을 모듈군 단위의 5 개 프롬프트(Memory, Reflection, Plan, Action, 그리고 Trajectory)로 분할하여 입력한다. 출력은 {item_id, verdict(true/false/null), evidence_step, rationale} 형식의 JSON 으로 강제하고, 스키마를 위반하면 1 회 재시도한 뒤 실패로 기록하며, temperature 는 0 으로 고정하고 정답 주석은 프롬프트에 포함하지 않는다. 장문 궤적은 스텝당 1,200 자와 궤적당 100,000 자로 절단하며(초과 시 앞 60%와 뒤 40%를 보존), 절단 정책은 판정 결과와 함께 보고한다. LLM 판정이 최종이며 인간 확정 단계는 없다. 둘째, L3 파생 계산 단계에서는 다음의 조작적 정의를 적용한다. 최초 오류 단계 t_0 는 L3-01 의 판정 단계(정답 대조 시에는 정답 단계)이고, 위치는 $t_0/(T-1)$ 의 3 분위(초반, 중반, 종반)이며, 전파 길이는 $(T-1)-t_0$ 이다. 자기 교정 시도는 t_0 이후 오류 인지 서술과 계획 변경이 함께 나타난 경우(L3-04)로, 유형 반복은 동일 항목의 긍정이 서로 다른 단계에서 2 회 이상 나타난 경우(L3-05)로 정의한다. 산출값은 < 표 10>(정답 주석 기반 분포, 실측)와 <표 11>(LLM 판정 발생 비율, 아직 수행하지 않음)이다.


판정 절차의 출처와 변경점은 다음과 같다. 궤적 전체를 한 번에 제시하고 판정을 받는 틀은 Who&When(Zhang et al., 2025)의 전체 일괄(all-at-once) 전략을 따른다. 이는 단계별 증분 판정 대비 호출 수가 크게 적고, 분류 체계를 프롬프트에 내장한 일괄 판정이 강한 기준선이 됨이 후속 연구에서도 확인되었기 때문이다(Ma et al., 2025; Barke et al., 2026). 궤적을 모듈군 단위로 나누어 판정하는 구성은 AgentDebug(Zhu et al., 2025)의 공개 구현(모듈별 분석 프롬프트)을 개작한 것이다. 원 구현 대비 변경점은 세 가지다. 첫째, 단일 오류의 지목 대신 26 항목 체크리스트의 항목별 예/아니오/

판정불가 판정으로 과제를 재정의하였다. 둘째, 프롬프트 분할을 기억, 반성, 계획, 행동의 4 개 인지 모듈군과 궤적(Trajectory) 항목군으로 재편하였다. 셋째, 근거 단계(evidence_step)와 판정 사유를 포함하는 JSON 출력을 강제하였다. 대표 프롬프트(기억 모듈군)는 [그림 5]와 같으며, 5 개 모듈군 프롬프트의 전문과 변형 b 는 부속 저장소에 공개한다.

<표 9> 증위별 진단가능성 커버리지 (실측, 26 항목, $p \geq 0.9$, 개수 (%))

벤치마크 (n)	L0 (/7)	L1 (/4)	L2 (/10)	L3 (/5)	전체
AEB ALFWorld (100)	4 (57.1)	1 (25.0)	10 (100)	5 (100)	76.9%
AEB WebShop (50)	4 (57.1)	1 (25.0)	10 (100)	5 (100)	76.9%
AEB GAIA (50)	4 (57.1)	1 (25.0)	4 (40.0)	4 (80.0)	50.0%
TRAIL GAIA (117)	5 (71.4)	3 (75.0)	4 (40.0)	4 (80.0)	61.5%
TRAIL SWE (31)	5 (71.4)	3 (75.0)	4 (40.0)	4 (80.0)	61.5%
Who&When AG (126)	3 (42.9)	0 (0.0)	3 (30.0)	4 (80.0)	38.5%
Who&When HC (58)	3 (42.9)	0 (0.0)	7 (70.0)	4 (80.0)	53.8%

주: 각 칸은 해당 층에서 판정 가능한 항목의 개수와 총 내 비율(%)이다. 항목별 필드 가용률 p 의 전체 행렬은 부속 저장소에 공개한다.




[그림 3] 벤치마크별 증위 커버리지 (실측)

커버리지 측정의 실측 결과는 <표 9> 및 [그림 3]과 같다. 진단가능성은 로그 형식에 따라 38.5%에서 76.9%까지 큰 차이를 보였으며, 층별로 나누어 보면 세 가지 특징이 확인된다. 첫째, 모듈 태그 형식을 강제한 AgentErrorBench 는 L2 계층의 10 개 항목이 모두 판정 가능한 반면 시스템 관측 계층의 항목들(성패 근거, 원시 응답, 메타데이터, 그리고 L1 의 3 개 항목)은 판정이 불가하였고, OTeI 스펠 기반의 TRAIL 에서는 L1 계층이 가장 높고(75.0%) L2 계층이 40.0%에 그쳐 이와 반대의 양상이 나타났다. 즉 인지 모듈에 대한 기록과 시스템 수준의 기록이 현존 벤치마크에서 동시에 확보되지 않음을 확인하였다. 둘째, 동일한 GAIA

과제가 AgentErrorBench 형식에서는 50.0%, TRAIL 형식에서는 61.5%로 측정되어, 진단가능성을 결정하는 요인이 과제가 아니라 로그 형식임이 직접 확인되었다. 셋째, AgentErrorBench의 정답 주석에는 스텝 한도 유형의 오류가 22 건 포함되어 있으나 한도 설정값이 로그에 존재하지 않아 L1-01은 판정이 불가하였다. 이는 주석자는 알고 있으나 로그만으로는 알 수 없는 간극이 실재함을 보여주는 사례로, 진단가능성 계측의 필요성을 뒷받침한다. 아울러 형식이 서로 다른 세 로그(모듈 태그, 발화 히스토리, 그리고 OTeI 스펠)에 단일 체크리스트가 모두 적용되었다는 사실 자체가 분류 체계 통합(기여 1)이 실제로 작동함을 보여주는 실증에 해당한다.

한편 매몰 근거(B)의 판정은 검출 패턴의 선택에 민감하다. 예를 들어 Who&When AG에서는 계획 관련 발화의 가용률이 53.2%로 임계값 90%에 미달하여 L2의 계획 항목군 전체가 판정불가로 분류되었으며, AEB GAIA에서는 memory와 reflection 태그의 가용률이 88%로 임계값에 근소하게 미달하였다. 이에 따라 임계값 p와 검출 패턴에 대한 민감도 분석 결과를 부속 저장소에 함께 공개한다.



[그림 4] 층위별 진단가능성 구성 (실측)

<표 10> 정답 주석 기반 최초 오류 분포 (실측: 3분위 위치와 전파 길이)

데이터 (n)	t ₀ 중앙값	위치 초/중/종반 (%)	전파 길이 평균/ 중앙값
Who&When 전체 (184)	4	48.4 / 26.6 / 25.0	14.4 / 5
— AG (126)	2	48.4 / 31.0 / 20.6	4.7 / 5
— HC (58)	12	48.3 / 17.2 / 34.5	35.5 / 18.5 (최대 124)
AEB 전체 (199†)	4	66.8 / 12.6 / 20.6	17.2 / 22
TRAIL 전체 (143‡)	8	30.1 / 48.3 / 21.7	19.0 / 10

† 골드 단계가 레직 범위를 초과한 1 건 제외. ‡ 오류 위치가 스펠에 사상되지 않거나 오류가 0 건인 5 건 제외. TRAIL의 다중 오류(레직당 평균 5.7 건)는 최초 위치를 채택.

정답 주석 기반 분포의 실측 결과는 <표 10>와 같다. 최초 오류는 Who&When과 AEB에서 레직 초반 1/3 구간에 크게 치우쳐 있으며(48~67%), 전파 길이는

궤적이 길수록 크게 늘어난다(Who&When HC 평균 35.5 단계, 최대 124 단계). 오류가 초반에 발생하여 종결까지 길게 이어지는 이러한 구조는, 궤적 길이가 늘어날수록 단계 귀인의 정확도가 급락한다는 원 벤치마크의 보고(Zhang et al., 2025)와 부합하는 독립적 근거이며, 조기 탐지와 개입의 가치를 정량적으로 뒷받침한다. 한편 TRAIL에서만 중반 편중(48.3%)이 나타났는데, 이는 스패 단위의 다중 오류 주석 방식의 차이 때문일 수 있으므로 주석 체계 간 위치 분포의 비교 가능성은 추가 검토가 필요하다.

<표 11> LLM 판정 기반 층위별 오류 발생 비율 (가상 결과 — 실행 후 실측 교체)

층	AEB	TRAIL	Who&When
L1 실행	무효 반복 7%	도구 오류 15% · 무효 행동 12%	(판정 대상 없음)
L2 사고	비효율 계획 31% · 진행 오판 19%	기억 회상 실패 21%	기억 환각 24% · 진행 오판 18%
L3 궤적	자기 교정 34% · 유형 반복 41%	유형 반복 33%	유형 반복 29%

주: 각 칸은 해당 벤치마크에서 판정 가능한 항목에 한하여, 발생 건수/판정 대상 건수의 비율로 산출한다. 실행 후 실측값으로 대체한다.

판정 모델 민감도는 전수 판정 결과로부터 모델 간 판정 일치율과, 정답 주석을 기준으로 한 모델별 정밀도(P)와 재현율(R)을 산출하여 측정한다(<표 12>). P와 R의 기준점은 정답 주석과 대조 가능한 판정(결정적 오류 단계 L3-01 과 해당 L2 모듈 및 유형)에 한정하며, 항목별 발생 비율의 신뢰성은 모델 간 일치와 자기 일관성으로만 서술한다. 이는 파일럿에서 확인된 모듈 판정의 관점 차이(4.4 절)를 고려한 것이다.

<표 12> 판정 모델 민감도 (가상 결과 — 실행 후 실측 교체)

항목군	모델 간 일치율	상위 P/R (골드 앵커)	저가 P/R (골드 앵커)
L1(보조)	0.96	0.98 / 0.97	0.97 / 0.95
L2 Memory·Reflection	0.79	0.84 / 0.78	0.80 / 0.58
L2 Plan·Action	0.83	0.87 / 0.81	0.83 / 0.66
L3(판정형)	0.81	0.85 / 0.76	0.79 / 0.61

저가 모델은 정밀도에서 상위 모델에 근접하였으나 재현율이 항목군에 따라 0.58~0.66 으로 낮았다. 오검은 적고 누락이 많은 이 패턴은, 저가 모델을 1 차 스크리닝으로 쓰고 긍정 후보만 상위 모델·인간이 확정하는 2 단 구성이 비용 효율적임을 시사한다.

판정 프롬프트 — 기억(Memory) 모듈군 (모듈군 5개 중 1)	
[System] 당신은 LLM 에이전트 실행 로그의 오류 진단 평가자다. 아래 실행 로그를 읽고 각 문항에 대해 증거가 명료할 때만 true로 판정하라. 반드시 JSON만 출력하라. 형식: {"items": [{"항목ID": "v": true/false/null, "step": int null, "why": "20자 내"}]}. null은 로그 정보 부족으로 판정불가인 경우다.	
[User] ## 문항 - L2-M1: 이전 기록에 없는 사실을 회상하는가 - L2-M2: 기록에 있는 정보를 회상하지 못하는가 - L2-M3: 요약이 과제 관련 핵심 세부를 누락하는가 ## 실행 로그 [TASK] {과제 명세, 1,500자 절단} [step 0] {{에이전트}} {단계 출력, 1,200자 절단} <obs> {환경 관찰, 400자 절단} [step 1] ... {배적당 100,000자 초과 시 앞 60%·뒤 40% 보존, 중간 생략 표기}	
temperature 0 · 정답 주석 미포함 · 스키마 위반 시 1회 제재도 · 변형 b: 문항 역순 + 지시문 제서술	

[그림 5] 기억 모듈군 판정 프롬프트 (5 개 모듈군 중 대표 1 중)

4.6 오류 정의의 조작화 가능성 분석

본 절에서는 제 2.3 절의 오류 정의 4 종이 각각 요구하는 로그 증거를 명세하고, 부속 저장소에 공개하는 필드 가용률 행렬(26 항목 × 7 서브셋)을 이용하여 서브셋별 채택 가능성을 판정한다. 판정 기준은 커버리지 측정과 동일하게 요구 필드의 가용률 $p \geq 0.9$ 이다. 네 정의는 공통적으로 단계별 오류 존재의 판정(D1의 기반)을 전제하며, 복구 불가 정의(D2)는 여기에 이후 단계의 복구 증거 판정을, 자가 복구 제외 정의(D4)는 다중 오류의 전수 표기를 추가로 요구한다. 반사실 정의(D3)는 해당 단계를 교정한 재실행이 성공으로 전환되는지의 확인을 요구하므로, 완결된 로그 내부의 증거가 아니라 재실행 가능한 환경이라는 로그 외 자원을 전제한다. 산출 결과는 <표 13>과 같다.

<표 13> 오류 정의 4 종의 요구 로그 증거와 조작화 가능성 (실측, $p \geq 0.9$)

정의 (출처)	추가 요구 증거	채택 가능 서브셋 (7 개 중)
D1 최초 실패 (Zhang et al., 2025)	단계별 오류 존재 판정(L2 판정가능 항목 1 개 이상) + 단계 인덱스(E)	7/7 — 단, Who&When AG는 판정가능 오류 유형이 기억·반성 계열 3 항목(L2-M1·M2·R1)으로 제한
D2 최초 복구 불가 실패 (Barke et al., 2026)	D1 + 이후 단계의 복구 증거: 반성 또는 계획 변화 기록(L3-04 필드)	2/7 (AEB ALFWorld·WebShop) — AEB GAIA 88%·Who&When HC 88%는 임계 근소 미달, TRAIL 0%·Who&When AG 51%는 불가
D3 반사실적 결정 오류 (Zhu et al., 2025; Ma et al., 2025)	해당 단계 교정 후 재실행의 성공 전환 확인 (재실행 가능 환경, 로그 외 자원)	0/7 — 완결 로그만으로는 조작화 불가. AgentFail의 수리 실험(Ma et al., 2025)은 플랫폼 재실행을 전제
D4 자가 복구 제외 (TELBench, 2026)	D2와 동일 + 다중 오류의 전수 표기(스패/단계 다중 주석 체계)	2/7 — D2와 동일 제약에 주석 체계 요구가 더해짐

주: 인간 주석자는 매물 근거(B)를 읽는 방식으로 D2를 판정할 수 있으나(AgentRx의 Who&When 재주석(Barke et al., 2026)이 그 예), 임계 p 기준의 자동 점검으로는 위와 같다. 임계를 $p \geq 0.85$ 로 완화하면 D2는 4/7(AEB GAIA-Who&When HC 포함)이 된다.

이 실측의 함의는 세 가지다. 첫째, 어떤 오류 정의를 채택할 수 있는지 자체가 로그의 관측 조건에 제약된다. 반성·계획 변화가 기록되지 않는 형식(TRAIL의 스펙, Who&When AG의 발화 이력)에서는 복구 불가 정의를 규칙적으로 조작화할 수 없으며, 따라서 AgentRx의 재주석과 Who&When 원 주석의 낮은 일치(44건 중 16건)(Barke et al., 2026)는 주석 품질의 문제가 아니라 정의와 관측 조건의 결합이 다른 두 측정의 예측된 차이로 읽어야 한다. 이로부터, 서로 다른 정의 위에서 산출된 단계 정확도들은 관측 조건과 오류 정의의 병기 없이는 비교될 수 없다는 보고 규범이 따라 나온다. 둘째, 반사실 정의가 완결 로그만으로 조작화되지 않는다는 결과(0/7)는 골드 주석의 생성 관행(재실행·개입 기반(Ma et al., 2025; REFLECT, 2026; AgenTracer, 2025))과 로그 단독 판정 사이의 구조적 간극을 드러낸다. 셋째, 반성·계획 변화 기록(L3-04 필드)이 정의 채택의 관문 필드로 확인되므로, 로깅 설계 지침에서 최우선 추가 대상이 된다.

4.7 종합 논의

종합하면 커버리지 측정은 "무엇을 판정할 수 있는 데이터인가"를, 정의 조작화 분석은 "어떤 오류 정의를 쟁할 수 있는 로그인가"를(이상 실측 완료), 판정 안정성 검증은 "판정이 안정적인가"를, 그리고 오류 분포 산출은 "판정이 무엇을 드러내고 얼마의 비용으로 가능한가"를 각각 담당한다. 실측이 완료된 두 분석과 정답 주석 기반 분포만으로도 본 연구의 핵심 주장, 즉 진단가능성은 로그 형식에 의해 결정되고, 관측 조건은 판정 항목뿐 아니라 채택 가능한 오류 정의까지 제약한다는 결론은 성립한다. 함의는 세 가지다. 첫째, 진단가능성 커버리지와 정의 조작화 가능성은 벤치마크 선택과 구축의 새 축을 제공하며, 귀인·진단 연구의 성능 보고에 관측 조건과 오류 정의를 함께 적도록 요구하는 근거가 된다. 둘째, 필요 로그 필드 명세와 한계 기여 분석은 역방향의 최소 로깅 설계 지침으로 기능하며, 특히 반성과 계획 변화 기록이 복구 불가 정의의 관문 필드로 확인되었다. 셋째, 판정 모델 민감도는 규칙 기반 층(L1)과 파생 항목에 결합하여 실무 진단 파이프라인의 비용 구조(무료 규칙층, 저가 스크리닝, 그리고 상위 확정)를 설계 가능하게 한다.

5. 결론

본 연구에서는 실패 진단 연구가 암묵적으로 전제해 온 "로그에 판정 근거가 있다"를 진단가능성이라는 측정 가능한 속성으로 승격시키고, 오류 분류 체계 5종을 사전 선언 규칙으로 교차 대응하여 판정 질문, 필요 로그 필드, 그리고 판정 방식의 3요소로 조작화한 4계층 26항목 점검 도구를 도출하였다. 도출된 도구를 공개 벤치마크 3종의 실패 궤적 532건 전수에 적용한 결과, 진단가능성이 과제가 아니라 로그 형식에 의해 결정되고(38.5~76.9%, 동일 GAIA 과제 50.0% 대 61.5%) 인지 기록과 시스템 기록이 상보적으로 누락됨을 확인하였으며, 오류 정의 4종의 요구 증거를 사상하여 복구 불가 정의는 7개 서브셋 중 2개에서만, 반사실 정의는 완결 로그만으로는 어디서도 조작화할 수 없음을 확인하였다. 정의의 채택 가능성 자체가 관측 조건에 제약된다는 이 결과는, 서로 다른 정의 위에서 산출된 귀인 정확도 수치가 관측 조건과 정의를 함께 적지 않고는 비교될 수 없음을 보여준다.

본 연구는 다음의 점에서 학술적 기여를 인정받을 수 있다. 첫째, 진단가능성을 방법의 부산물이 아니라 독립적인 측정 대상으로 정식화하고, 이를 실행 로그만으로 판정 가능한 도구로 조작화하였다. 둘째, 형식이 서로 다른 세 벤치마크를 가로지르는 교차 계측으로 관측 조건이 판정 항목과 채택 가능한 오류 정의를 함께 제약을 실측으로 보였다. 셋째, 파편화된 분류 체계 5종의 교차 대응표와 오류 정의 4종의 요구 증거 사상은 후속 연구가 재사용할 수 있는 기반 자료가 된다.

실무적 기여는 다음과 같다. 에이전트를 운영하는 조직은 본 도구를 통해 사고 후 원인 분석이 가능한 로그 상태인지를 사전에, 비용 없이 점검할 수 있으며, 자동 진단 도구의 도입 전에 해당 도구가 요구하는 관측 조건의 충족 여부를 확인하는 선행 게이트로 활용할 수 있다. 필드별 한계 기여 분석은 어떤 기록을 추가하면 어떤 판정과 어떤 오류 정의가 가능해지는지의 우선순위를 제공하므로 관측 스택과 로깅 스키마 설계의 근거가 되며, 특히 반성과 계획 변화 기록이 복구 불가 정의 채택의 관문 필드로 확인되었다. 나아가 진단가능성 점수와 필요 필드 명세는 기록 의무를 요구하는 규제 환경에서 검사 가능한 기준의 원형으로 활용될 수 있을 것으로 기대한다.

다만 본 연구는 다음의 한계를 갖는다. 첫째, 본 버전은 단일 에이전트 로그를 범위로 하며, 제외 목록으로 보존된 멀티에이전트 유형의 확장은 후속 버전의 과제다. 둘째, 오류 정의 4종의 요구 증거 환경에는 본 연구의 해석이 개입되어 있으며, 정의 간 일치 조건의 형식적

증명과 AgentRx 와 Who&When 의 불일치 28 건을 정의 성분과 잡음 성분으로 분해하는 실증은 향후 연구로 남긴다. 셋째, 항목 판정은 LLM 단독으로 수행되어 독립적인 인간 이중 코딩을 결여하며, 이중 모델 간 일치, 프롬프트 변형 자기 일관성, 그리고 원 벤치마크 인간 주석과의 정합도를 신뢰성의 대리 지표로 보고한다. 넷째, 매물 근거 검출 패턴과 임계값의 선택이 커버리지 수치에 영향을 주므로 민감도 분석을 함께 적을 필요가 있다. 향후 연구에서는 실측 근거에 기반한 최소 로깅 스키마를 설계과학 인공물로 정식화하고, 진단가능성 점검, 오류 분포 분석, 그리고 결정적 오류 귀인으로 이어지는 통합 진단 파이프라인과 감리 기준화로 발전시키고자 한다.

참고문헌

- "AgenTracer: Tracing Failures in Multi-Agent Systems via Counterfactual Replay and Fault Injection", arXiv preprint arXiv:2509.03312, 2025. (저자 확인 예정)
- "AgentProcessBench: Diagnosing Step-Level Process Quality of Tool-Augmented Agent Trajectories", arXiv preprint arXiv:2603.14465, 2026. (저자 확인 예정)
- Barke, S., A. Goyal, A. Khare, A. Singh, S. Nath, and C. Bansal, "AgentRx: Diagnosing AI Agent Failures from Execution Trajectories", arXiv preprint arXiv:2602.02475, 2026.
- Cemri, M. et al., "Why Do Multi-Agent LLM Systems Fail?", arXiv preprint arXiv:2503.13657, 2025.
- Cohen, J., "A Coefficient of Agreement for Nominal Scales", Educational and Psychological Measurement, Vol.20, No.1, 1960, 37-46.
- "Conformal Agent Error Attribution", arXiv preprint arXiv:2605.06788, 2026. (저자 확인 예정)
- Deshpande, D., V. Gangal, H. Mehta, J. Krishnan, A. Kannappan, and R. Qian, "TRAIL: Trace Reasoning and Agentic Issue Localization", arXiv preprint arXiv:2505.08638, 2025.
- "Early Diagnosis of Wasted Computation in Multi-Agent LLM Systems via Failure-Aware Observability", arXiv preprint arXiv:2606.01365, 2026. (저자 확인 예정, 본문 인용 표기 Failure-Aware Observability)
- Hevner, A.R., S.T. March, J. Park, and S. Ram, "Design Science in Information Systems Research", MIS Quarterly, Vol.28, No.1, 2004, 75-105.
- ISO/IEC, "ISO/IEC 42001:2023 Information Technology - Artificial Intelligence - Management System", ISO, 2023.
- Landis, J.R. and G.G. Koch, "The Measurement of Observer Agreement for Categorical Data", Biometrics, Vol.33, No.1, 1977, 159-174.
- Ma, X., X. Xie, Y. Wang, J. Wang, B. Wu, M. Li, and Q. Wang, "Diagnosing Failure Root Causes in Platform-Orchestrated Agentic Systems: Dataset, Taxonomy, and Benchmark", arXiv preprint arXiv:2509.23735, 2025. (데이터셋 명칭 AgentFail)
- Nickerson, R.C., U. Varshney, and J. Muntermann, "A Method for Taxonomy Development and Its Application in Information Systems", European Journal of Information Systems, Vol.22, No.3, 2013, 336-359.
- NIST, "Artificial Intelligence Risk Management Framework (AI RMF 1.0)", NIST AI 100-1, 2023.
- "Oat: Unsupervised Error Attribution for LLM Agents via One-Class Learning", arXiv preprint arXiv:2607.12747, 2026. (저자 확인 예정)
- OpenTelemetry and Arize AI, "OpenInference: Semantic Conventions for AI Observability", <https://github.com/Arize-ai/openinference>, 2025.
- Peffer, K., T. Tuunanen, M.A. Rothenberger, and S. Chatterjee, "A Design Science Research Methodology for Information Systems Research", Journal of Management Information Systems, Vol.24, No.3, 2007, 45-77.
- Rabanser, F. et al., "Towards a Science of AI Agent Reliability", Proceedings of the International Conference on Machine Learning(ICML), 2026. (서지 확인 예정)
- "REFLECT: Intervention-Supported Error Attribution for LLM Agent Traces", arXiv preprint arXiv:2606.09071, 2026. (저자 확인 예정)
- Sampath, M., R. Sengupta, S. Lafortune, K. Sinnamohideen, and D. Teneketzis, "Diagnosability of Discrete-Event Systems", IEEE Transactions on Automatic Control, Vol.40, No.9, 1995, 1555-1575.
- "Seeing the Whole Elephant: A Benchmark for Failure Attribution in LLM-based Multi-Agent Systems", arXiv preprint arXiv:2604.22708,

2026. (저자 확인 예정, 본문 인용 표기 Whole Elephant)

"TELBench: Span-Level Error Localization for Deep-Research Agent Trajectories", arXiv preprint arXiv:2606.02060, 2026. (저자 확인 예정)

"TraceElephant: Complete-Observation Traces for Agent Failure Attribution", 2026. (저자 확인 예정)

Wang, L. et al., "A Survey on Large Language Model based Autonomous Agents", Frontiers of Computer Science, Vol.18, 186345, 2024.

Yao, S. et al., "ReAct: Synergizing Reasoning and Acting in Language Models", Proceedings of the International Conference on Learning Representations(ICLR), 2023.

Zhang, S. et al., "Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems", Proceedings of the 42nd International Conference on Machine Learning(ICML), PMLR 267, 2025.

Zhu, K. et al., "Where LLM Agents Fail and How They Can Learn From Failures", arXiv preprint arXiv:2509.25370, 2025.

Zhu, K. et al., "AgentDebugX: An Open-Source Toolkit for Failure Observability, Attribution, and Recovery in LLM Agents", arXiv preprint arXiv:2607.18754, 2026. (서지 확인 예정)

※ (저자 확인 예정)으로 표시한 항목은 투고 전 원문 확인 후 저자명 기준의 인용 표기로 정비한다. 저자명 000 는 투고 시 확정한다.